République Islamique de Mauritanie
Université de Nouakchott - UN
Faculté des Sciences et Techniques
Département d'Informatique
Master « Systèmes d'Information »

Classification des régimes de marché du taux de change MRU/USD par apprentissage automatique : impact du choix des labels et de la validation temporelle

Mémoire présenté en vue de l'obtention du Diplôme de Master en Systèmes d'Information (SI)

Domaine : Informatique, Sciences des Données et Réseaux (ISDR)

Al-Khawarizmi

Étudiant : **Mohamed Vadel Hadweni - C18041**

Encadrant : **Prof. Mohamedou El Ghotob Cheikh Tourad**

Année universitaire 2024–2025

Dédicace

À mes parents et à ma famille, pour leur soutien constant et leur confiance.

"In God we trust; all others must bring data."

W. Edwards Deming [1]

Remerciements

Je remercie Dieu pour la santé, la patience et la force qu'Il m'a accordées tout au long de ce travail, et qui m'ont permis de mener ce mémoire à son terme.

Je tiens à exprimer ma profonde reconnaissance à mes parents pour leur soutien constant, leurs encouragements et les valeurs qu'ils m'ont transmises, et qui ont constitué un appui essentiel durant mon parcours académique.

J'adresse mes sincères remerciements à Prof. Mohamedou El Ghotob Cheikh Tourad, mon encadrant, pour son accompagnement, sa disponibilité et la qualité de ses conseils tout au long de la réalisation de ce travail.

Je remercie également mes amis pour leur soutien moral, leurs encouragements et les échanges constructifs qui ont accompagné cette période de travail.

Enfin, je remercie ma famille pour sa patience, sa compréhension et son soutien tout au long de la réalisation de ce mémoire.

Abstract

La classification des régimes de marché consiste à attribuer chaque jour de cotation à un état précis, comme baissier, neutre ou haussier. Ce mémoire se penche sur la classification supervisée des régimes appliquée au taux de change quotidien MRU/USD, en utilisant une étude de cas contrôlée en apprentissage automatique. L'objectif est d'isoler l'impact de (i) la conception des labels et (ii) de la validation en séries temporelles sur ce que les modèles supervisés peuvent réellement apprendre. L'analyse se concentre délibérément sur un seul actif (MRU/USD) : les conclusions doivent donc être interprétées comme des observations spécifiques, sans garantie de généralisation à d'autres marchés.

L'étude repose sur une série OHLC MRU/USD soigneusement nettoyée, limitée aux jours ouvrés, couvrant la période du 03-01-2000 au 25-11-2025 (6 752 observations). Deux définitions de régimes sont mises en comparaison. La première, L1_Q, est un label à trois classes basé sur des quantiles de rendements logarithmiques futurs sur un horizon de cinq jours, avec des seuils ajustés uniquement sur la fenêtre d'entraînement. La seconde, L2, est un label de tendance à trois classes défini par un croisement de moyennes mobiles MA10/MA50, complété par un filtre de pente sur la moyenne lente.

L'évaluation suit rigoureusement la dimension temporelle selon deux schémas : (i) un split chronologique unique de type holdout (V1), et (ii) une validation walk-forward avec des fenêtres d'entraînement extensibles et des fenêtres de test disjointes (V2). Les modèles choisis sont délibérément simples et transparents — régression logistique multiclasse et SVM linéaire — et sont entraînés sur un ensemble compact de caractéristiques basé uniquement sur les prix de clôture, calculé à partir des informations disponibles jusqu'à $t - 1$, avec une standardisation effectuée uniquement sur l'entraînement.

Les résultats indiquent que les choix de labellisation influencent fortement la performance de classification : L2 atteint une Macro-F1 nettement plus élevée (≈ 0.41–0.44) que L1_Q (≈ 0.24–0.28). Toutefois, les deux familles de labels présentent un mode d'échec persistant sur le régime neutre, mis en évidence par les diagnostics par classe. Enfin, une couche minimale de backtesting traduit les régimes prédits en positions longues, courtes ou neutres avec un décalage d'exécution d'un jour, et compare les résultats à des baselines transparentes. La performance de trading est utilisée comme un diagnostic en aval, et non comme un objectif d'optimisation.

Table des matières

0.0.1. Liste des figures ... VII
0.0.2. Liste des figures ... VIII
0.0.3. Liste des tables ... IX
0.0.4. Liste des tables ... X

1. Résumé ... 1

2. Introduction ... 2
2.1. Motivation ... 2
2.2. Questions de recherche ... 3
2.3. Contributions ... 3
2.4. Plan du mémoire ... 4

3. Contexte méthodologique ... 5
3.1. Validation en séries temporelles et fuites d'information ... 5
3.1.1. Pourquoi la validation en séries temporelles est différente ... 5
3.1.2. Schémas de validation utilisés dans ce mémoire (V1 et V2) ... 6
3.1.3. Contrôles anti-leakage utilisés dans ce projet ... 7
3.1.4. Fuite de frontière pour les labels à horizon futur (limitation documentée) . 7
3.2. Stratégies d'étiquetage (labels) en finance ... 8
3.2.1. Les labels définissent le problème d'apprentissage ... 8
3.2.2. L1_Q : régimes par quantiles du rendement futur ($k = 5$) ... 8
3.2.3. L1_extreme : régimes à seuil volatilité-scalé ($k = 5$, $\lambda = 0.75$) ... 9
3.2.4. L2 : croisement de moyennes mobiles avec filtre de pente MA lente (MA10/MA50, $h = 5$) ... 9
3.2.5. Alignement causal des features (information disponible jusqu'à $t - 1$) . . 10
3.3. Métriques de performance (Accuracy, Macro-F1) ... 11
3.3.1. Conventions pour les matrices de confusion et ordre des classes ... 11
3.3.2. Accuracy ... 11
3.3.3. Précision, rappel, F1 et Macro-F1 ... 11
3.3.4. Gestion déterministe des valeurs indéfinies lorsqu'une classe n'est jamais prédite ... 12
3.4. Résumé des implications méthodologiques clés ... 12

4. Travaux connexes ... 13
4.1. Régimes de marché : définitions et traditions de modélisation ... 13
4.2. Baselines linéaires pour la classification de régimes en données limitées ... 14
4.2.1. Machines à vecteurs de support (SVM) ... 15

4.2.2. Régression logistique ... 15
4.3. Méthodologie de validation pour données financières dépendantes temporellement ... 16
4.3.1. Pourquoi la validation i.i.d. est invalide par défaut ... 16
4.3.2. Évaluation walk-forward et outillage ... 16
4.3.3. Fuite au-delà de « train après test » : recouvrement, purge et embargo ... 17
4.3.4. Tests multiples et surapprentissage des backtests ... 17
4.4. Construction des labels de régimes financiers et pièges courants ... 18
4.4.1. Labels à horizon fixe basés sur le rendement ... 18
4.4.2. Labels de tendance et fragmentation ... 18
4.4.3. Labels basés sur des événements et sémantique économique ... 18
4.4.4. Contexte : marchés moins étudiés ou données limitées ... 19
4.5. Synthèse : leçons méthodologiques motivant ce mémoire ... 20

5. Données et prétraitement ... 21
5.1. Sources de données et justification de la sélection ... 21
5.1.1. Série principale ... 21
5.1.2. Sources alternatives considérées (sanity-check uniquement) ... 21
5.2. Structure du jeu de données brut et audit des valeurs manquantes ... 22
5.2.1. Structure du fichier brut ... 22
5.2.2. Disponibilité des OHLC et « jours sans prix » ... 22
5.2.3. Qualité des colonnes et décisions de conservation ... 23
5.3. Construction de la série OHLC nettoyée ... 24
5.3.1. Objectifs du nettoyage ... 24
5.3.2. Règles de nettoyage ... 24
5.3.3. Résumé du jeu de données nettoyé (contrat de données) ... 25
5.4. Séries dérivées pour l'analyse en aval ... 25
5.4.1. Rendements ... 25
5.4.2. Volatilité glissante (30 jours et 90 jours) ... 26
5.4.3. Artefact dérivé sauvegardé ... 26
5.5. Périmètre et limites du prétraitement ... 27
5.5.1. Périmètre et non-objectifs ... 27
5.5.2. Dépendance au fournisseur et comparabilité ... 27
5.5.3. Interprétation du calendrier et effets de warm-up ... 27

6. Conception des labels ... 28
6.1. Ouverture du chapitre ... 28
6.2. Définition des labels fondés sur le rendement (L1) ... 30
6.2.1. Cible de rendement futur et horizon ... 30
6.2.2. L1_Q (seuils par quantiles) et période d'ajustement des seuils ... 30
6.2.3. Variante L1 documentée : L1_extreme (seuil mis à l'échelle par la volatilité) ... 31

6.2.4. Timing/disponibilité et considérations de frontière en évaluation 31
6.3. Définition des labels fondés sur des indicateurs (L2) 32
6.3.1. Indicateurs et paramètres 32
6.3.2. Mapping exact à trois classes 32
6.3.3. Zone de warm-up, labels indéfinis et traitement des lignes 33
6.3.4. Risque de circularité et atténuation par exclusion de features 33
6.4. Distributions de classes pour L1 vs L2 34
6.4.1. Distributions globales (résumé label-only) 34
6.4.2. Distributions globales (table de modélisation fusionnée utilisée dans les expériences) 35
6.4.3. Distributions V1 après alignement local par segment (échantillons effectifs) 36
6.4.4. Distributions des fenêtres de test V2 par pli (dérivées des totaux de lignes des matrices de confusion) 37
6.5. Contrat de reproductibilité pour l'alignement labels–features 38
6.6. Résumé du chapitre 38

7. Jeu de features et configuration des modèles 39
7.1. Features cœur (F_CORE) 39
7.1.1. Entrées et notations 39
7.1.2. Règle de timing de l'information (alignement causal) 39
7.1.3. Définition exacte de F_CORE 40
7.1.4. Warm-up et gestion des NaN 40
7.2. Features additionnelles (définies mais exclues des baselines) 41
7.2.1. Features de niveau à base de moyennes mobiles (définies, hors F_CORE) 41
7.2.2. Indicateur de forte volatilité (défini, calibré sur train) 41
7.2.3. Anti-circularité pour L2 (séparation features–label) 41
7.3. Choix des modèles (Régression logistique, SVM linéaire) 42
7.3.1. Contrôle de reproductibilité (convention de seed) 42
7.3.2. Hyperparamètres figés par conception 42
7.3.3. Configurations figées 42
7.4. Protocole d'entraînement (alignement, mise à l'échelle, et "plomberie" d'évaluation) 43
7.4.1. Alignement local à la fenêtre et filtrage 43
7.4.2. Mise à l'échelle (ajustement sur l'entraînement uniquement) 43
7.4.3. Métriques et sorties de diagnostic 44
7.5. Contrôles de fuite et de circularité 44
7.5.1. Prévention du look-ahead côté features (implémenté) 44
7.5.2. Prévention de la circularité L2 (implémenté) 44
7.5.3. Fuite de frontière pour les labels L1 à horizon futur (limitation documentée) 44

7.6. Résumé du chapitre ... 45

8. Protocole expérimental ... 46
8.1. Contrats expérimentaux fixes ... 46
8.2. Fenêtres d'évaluation respectant le temps ... 47
8.2.1. V1 : holdout chronologique ... 47
8.2.2. V2 : plis **walk-forward** à fenêtre croissante ... 48
8.3. Alignement local aux fenêtres et gestion des valeurs manquantes ... 48
8.3.1. Règle d'alignement ... 48
8.3.2. Politique NaN ... 48
8.4. Prétraitement et contrôles de fuite d'information ... 49
8.4.1. Causalité des features ... 49
8.4.2. Standardisation **train-only** ... 49
8.4.3. Effets de frontière pour les labels à horizon futur ... 49
8.5. Procédures d'entraînement et d'évaluation ... 50
8.5.1. Paramètres communs ... 50
8.5.2. Procédure V1 ... 50
8.5.3. Procédure V2 ... 50
8.6. Persistance pour la reproductibilité ... 51
8.7. Agrégation **walk-forward** ... 51
8.7.1. Moyenne des métriques par pli ... 51
8.7.2. Matrice de confusion agrégée ... 52
8.8. Contrôle du périmètre expérimental ... 52

9. Résultats de classification et diagnostics ... 53
9.1. Portée du chapitre et norme de rapport ... 53
9.2. Contrat expérimental commun pour E1–E8 ... 54
9.2.1. Ensemble de features (F_CORE) ... 54
9.2.2. Politique NaN (filtre explicite) ... 54
9.2.3. Contrôle de fuite d'information et métriques d'évaluation ... 54
9.2.4. Environnement d'exécution enregistré ... 54
9.3. Disponibilité des labels et diagnostics d'équilibre des classes ... 55
9.3.1. Contrôle d'intégrité du label L2 et distribution globale ... 55
9.3.2. Équilibre des classes L2 par segment V1 (après filtrage) ... 55
9.4. Performance de test synthétique sur E1–E8 (Macro-F1 et accuracy) ... 56
9.4.1. Interprétation ... 56
9.5. Résultats et diagnostics L1_Q (E1–E4) ... 56
9.5.1. Comportement en holdout V1 (E1 vs E3) ... 56
9.5.2. Comportement **walk-forward** V2 (E2 vs E4) ... 57
9.6. Résultats et diagnostics L2 (E5–E8) ... 58
9.6.1. Métriques V1 (E5 vs E6) ... 58
9.6.2. Diagnostics par matrices de confusion (L2, test V1) ... 58

9.7. Résultats pli par pli sous V2 (E7 vs E8) ... 59
9.8. Diagnostic inter-familles : désaccord entre labels (L1_Q vs L2) ... 61
9.9. Synthèse des modes de défaillance (résumé des baselines) ... 62
9.10. Conclusion du chapitre et transition vers le Chapitre 10 ... 62

10. Backtesting et analyse de stratégies ... 63
10.1. Spécification du backtest ... 63
10.1.1. Prix et définition des rendements ... 63
10.1.2. Espace des signaux et timing d'exécution ... 64
10.1.3. Rendement de la stratégie ... 64
10.1.4. Coûts de transaction ... 64
10.2. Stratégies et baselines ... 65
10.2.1. Stratégies issues de l'apprentissage automatique ... 65
10.2.2. Stratégies de référence ... 65
10.3. Métriques rapportées ... 65
10.4. Résultats sous V1 (fenêtre de test chronologique unique) ... 66
10.4.1. Figure — Courbes d'équité sous V1 ... 67
10.5. Résultats sous V2 (plis walk-forward) ... 67
10.5.1. Performance par pli ... 68
10.5.2. Performance agrégée ... 68
10.5.3. Figures — Courbes d'équité V2 par pli ... 69
10.6. Comportement de classification et résultats de trading ... 70
10.7. Conclusion du chapitre ... 70

11. Discussion et menaces à la validité ... 71
11.1. Interprétation des résultats ... 71
11.2. Comment la classification se traduit en backtest ... 72
11.3. Comparaison aux attentes ... 72
11.4. Menaces à la validité ... 73
11.4.1. Validité de construit (définitions des labels) ... 73
11.4.2. Validité interne (fuite d'information et risques d'alignement) ... 73
11.4.3. Validité des conclusions statistiques (variance et support de test limité) . 73
11.4.4. Validité externe (généralisation) ... 74
11.4.5. Validité du backtest (hypothèses simplificatrices) ... 74
11.5. Limites pratiques et synthèse ... 74

12. Conclusions et perspectives ... 75
12.1. Réponses aux questions de recherche ... 76
12.2. Contributions ... 76
12.3. Limites ... 77
12.4. Perspectives ... 78

12.5. Conclusion générale 78

Références ..... a

Liste des figures

Fig. 1 Chronologie de validation (V1 holdout et plis V2 walk-forward). 28

Fig. 2 Génération des labels : (L1) rendements futurs à horizon k=5 puis application de seuils ; (L2) indicateurs MA10/MA50 et filtre de pente puis affectation de la classe −1/0/+1. 29

Fig. 3 Régimes L1_Q superposés au prix de clôture (sanity check de la définition L1). 31

Fig. 4 Régimes L2 superposés au prix de clôture (sanity check de la définition L2). 33

Fig. 5 Accord entre familles de labels (L1_Q vs L2) — heatmap sur la chronologie commune. 35

Fig. 6 Vue d'ensemble du pipeline expérimental : données → features (alignement causal) → génération des labels → splits temporels (V1/V2) → entraînement et évaluation. 46

Fig. 7 Fréquence des classes prédites L1_Q sur le test V1 (E1). 57

Fig. 8 Fréquence des classes prédites L1_Q sur le test V1 (E3). 57

Fig. 9 Fréquence des classes prédites L1_Q agrégée sur les tests des plis V2 (E2). . 57

Fig. 10 Fréquence des classes prédites L1_Q agrégée sur les tests des plis V2 (E4). . 57

Fig. 11 Fréquence des classes prédites L2 sur le test V1 (E5). 59

Fig. 12 Fréquence des classes prédites L2 sur le test V1 (E6). 59

Fig. 13 Fréquence des classes prédites pour L2, agrégée sur les plis de test V2 (E7). 60

Fig. 14 Fréquence des classes prédites pour L2, agrégée sur les plis de test V2 (E8). 60

Fig. 15 Carte de chaleur du désaccord entre labels (L1_Q vs L2). 61

Fig. 16 Courbes d'équité sous V1 (T1, T2, B1 et B2). 67

Fig. 17 Courbe d'équité sous V2, pli F1. 69

Fig. 18 Courbe d'équité sous V2, pli F2. 69

Fig. 19 Courbe d'équité sous V2, pli F3. 69

Fig. 20 Courbe d'équité sous V2, pli F4. 69

Liste des tables

Tableau 1 Fenêtres de validation (V1 et V2) 6

Tableau 2 Correspondance colonnes brutes → colonnes nettoyées (OHLC) 23

Tableau 3 Résumé du jeu OHLC nettoyé (contrat de données) 25

Tableau 4 Distribution globale des labels (label-only, y compris NaN) 34

Tableau 5 Distribution globale des labels (table fusionnée, y compris NaN) 35

Tableau 6 Équilibre des classes V1 (L1_Q, après alignement/filtrage NaN) 36

Tableau 7 Équilibre des classes V1 (L2, après alignement/filtrage NaN) 36

Tableau 8 Équilibre des classes V2 par pli (L1_Q, fenêtres test) 37

Tableau 9 Équilibre des classes V2 par pli (L2, fenêtres test) 37

Tableau 10 Définitions des features cœur et timing. 40

Tableau 11 Contrat de persistance. 51

Tableau 12 Distribution du label L2 sur le jeu de données fusionné (NaN inclus). . 55

Tableau 13 Effectifs des classes L2 par segment V1 utilisés pour l'entraînement/évaluation (après suppression des NaN). 55

Tableau 14 Synthèse des performances sur l'ensemble de test (accuracy et Macro-F1). 56

Tableau 15 Métriques L2 sous V1 (E5, régression logistique). 58

Tableau 16 Métriques L2 sous V1 (E6, LinearSVC). 58

Tableau 17 Matrice de confusion L2 (E5, test V1 ; ordre des classes [−1, 0, +1]). . . . 58

Tableau 18 Matrice de confusion L2 (E6, test V1 ; ordre des classes [−1, 0, +1]). . . . 58

Tableau 19 Métriques de test par pli sous V2 (E7, Régression logistique). 59

Tableau 20 Métriques de test par pli sous V2 (E8, LinearSVC). 60

Tableau 21 Rendement logarithmique cumulé et drawdown maximal par pli sous V2. 68

Tableau 22 Performance moyenne sur les plis V2. 68

1. Résumé

Ce mémoire est une étude reproductible, pilotée par l'expérimentation, sur la classification supervisée de régimes de marché pour MRU/USD sous une évaluation stricte en séries temporelles. Il s'appuie sur trois engagements de conception, testés sans élargissement du périmètre en cours de route :

1. **Les régimes sont définis explicitement.** Deux définitions de régimes sont traitées comme des choix de modélisation de premier ordre : (i) un label par quantiles du rendement futur (horizon 5 jours, trois classes) et (ii) un label de tendance par moyennes mobiles avec filtre de pente (trois classes).
2. **Le protocole de validation sanctuarise la structure temporelle** via une segmentation chronologique de type holdout et un schéma walk-forward à ancrage fixe et fenêtre d'apprentissage incrémentale, neutralisant ainsi les risques de fuite de données inhérents aux méthodes de validation croisée aléatoire. Ordre temporel blindé.
3. **Le périmètre algorithmique se restreint à la régression logistique** et au SVM à noyau linéaire afin de garantir l'auditabilité mathématique du système. L'analyse post-modélisation délaisse les métriques holistiques au profit de diagnostics granulaires par classe, exploitant l'examen exhaustif des matrices de confusion pour prévenir tout masquage d'effondrement de classe. Transparence par construction.

Une simulation de **backtesting** élémentaire convertit les vecteurs de probabilités en signaux positionnels pour les confronter à des référentiels de base. Ce contrôle de cohérence évalue si la variance des sorties de classification génère une divergence comportementale significative au sein de la stratégie. Vérification empirique directe.

2. Introduction

2.1. Motivation

Les séries temporelles financières sont souvent décrites en termes de « régimes » : périodes soutenues d'appréciation, de dépréciation, ou de mouvement latéral. Formuler cette intuition comme un problème d'apprentissage supervisé paraît direct — définir un label par jour, entraîner un classifieur, puis rapporter des performances — mais les conclusions dépendent fortement de deux choix de conception souvent sous-spécifiés : la définition des régimes (labellisation) et l'évaluation de la généralisation dans le temps (validation).

Ce mémoire utilise MRU/USD comme étude de cas ciblée. Le jeu de données est une série OHLC nettoyée (jours ouvrés uniquement) couvrant 2000-01-03 à 2025-11-25 (6752 observations). Le but n'est pas de « découvrir des régimes » au sens non supervisé ; il s'agit d'évaluer si des modèles supervisés simples peuvent apprendre des régimes définis par des règles sous une évaluation respectant l'ordre temporel, et de documenter les modes d'échec lorsqu'ils apparaissent. Cette focalisation sur un seul actif limite la portée empirique du travail : les comportements observés peuvent différer sur d'autres marchés.

Une première motivation est la sensibilité méthodologique : en apprentissage automatique appliqué à la finance, la définition de la cible fait partie intégrante du problème. Ce travail compare donc deux constructions de régimes qui encodent des hypothèses différentes : un label fondé sur des quantiles de rendement futur et un label de tendance dérivé de moyennes mobiles, complété par un filtre de pente.

Une deuxième motivation concerne la rigueur de l'évaluation. Comme les observations sont temporellement dépendantes, toute estimation de généralisation doit préserver l'ordre chronologique et empêcher les fuites d'information (leakage). Cela motive une évaluation respectueuse du temps via un découpage chronologique de type holdout et des plis walk-forward à fenêtre d'apprentissage croissante.

Enfin, le projet est volontairement contraint. Les modèles centraux sont linéaires (régression logistique et SVM linéaire) afin de limiter les degrés de liberté, garantir des comparaisons équitables et faciliter l'audit des modes d'échec (p. ex. effondrement de la classe neutre).

2.2. Questions de recherche

Pour éviter tout déplacement d'objectif a posteriori, le mémoire est structuré autour de trois questions de recherche prédéfinies :

RQ1 — Conception des labels. Comment la définition d'un « régime » affecte-t-elle l'apprenabilité sur MRU/USD ? Plus précisément, comment les résultats diffèrent-ils lorsque les régimes sont définis par quantiles de rendement futur versus par états de tendance (moyennes mobiles + filtre de pente) ?

RQ2 — Protocole de validation. Dans quelle mesure les conclusions sont-elles sensibles au schéma d'évaluation ? En particulier, comment un unique découpage chronologique holdout et des plis walk-forward à fenêtre d'apprentissage croissante modifient-ils la performance rapportée et sa stabilité dans le temps ?

RQ3 — Comportement aval du signal. Lorsque les régimes prédits sont convertis en positions via un backtest minimal et transparent, les stratégies obtenues se distinguent-elles de baselines simples, et ces différences sont-elles cohérentes avec les diagnostics de classification observés (y compris les modes d'effondrement) ?

2.3. Contributions

Ce travail propose un cadre reproductible et volontairement restreint pour la classification de régimes sur une unique série financière, en privilégiant l'auditabilité plutôt que la complexité :

C1 — Comparaison contrôlée de schémas d'étiquetage. L'étiquetage est traité comme une décision de modélisation : deux familles de régimes (rendements futurs vs indicateurs) sont comparées dans des conditions harmonisées.

C2 — Évaluation en séries temporelles sous deux protocoles explicites. Le mémoire applique un découpage chronologique holdout et des plis walk-forward à fenêtre d'apprentissage croissante, afin de mesurer directement l'effet du design de validation sur les conclusions.

C3 — Rapport "diagnostic-first" des modes d'échec. Au-delà des métriques agrégées, l'évaluation privilégie des résultats par classe et des matrices de confusion pour rendre visibles des effondrements (notamment la difficulté à prédire le régime neutre) que l'accuracy peut masquer.

C4 — Pont minimal entre classification et comportement de stratégie. Les régimes prédits sont convertis en positions et comparés à des baselines simples comme diagnostic aval : l'objectif est de vérifier si le comportement de classification se traduit en comportement de trading distinct, sans transformer l'étude en optimisation du profit.

2.4. Plan du mémoire

Le reste du mémoire sépare la définition du problème des preuves expérimentales :

- **(Contexte / Background) :** cadrage de la classification de régimes, validation en séries temporelles, risques de fuite d'information, métriques d'évaluation.
- **(Travaux connexes) :** approches existantes sur les régimes et pratiques de validation temporelle en ML financier.
- **(Données et prétraitement) :** construction du jeu MRU/USD, nettoyage, séries dérivées.
- **(Étiquetage) :** définitions formelles des deux schémas de labels, disponibilité, implications sur l'équilibre des classes.
- **(Variables et modèles) :** définition du bloc de variables compact et mise en place des modèles linéaires.
- **(Protocole expérimental) :** frontières chronologiques et **walk-forward**, agrégation des plis, règles de génération d'artefacts.
- **(Résultats de classification) :** résultats et diagnostics, en mettant l'accent sur l'effet labels/validation et les effondrements.
- **(Backtesting) :** conversion prédiction→position, baselines, diagnostics au niveau stratégie.
- **(Discussion et menaces à la validité) :** interprétation, limites, risques méthodologiques.
- **(Conclusion) :** réponses à RQ1–RQ3 et pistes de travaux futurs.

3. Contexte méthodologique

Ce chapitre introduit les concepts méthodologiques nécessaires pour interpréter le design expérimental et les résultats de la classification de régimes de marché MRU/USD. Il s'articule autour de trois piliers :

1. **Validation en séries temporelles et contrôle des fuites d'information** (pourquoi l'évaluation temporelle diffère du cas i.i.d.),
2. **Stratégies d'étiquetage des régimes** (comment les cibles supervisées sont construites et quelles hypothèses elles codent),
3. **Métriques de performance** (pourquoi l'accuracy seule est insuffisante et pourquoi la Macro-F1 et les matrices de confusion sont rapportées).

Un chapitre séparé (« Travaux connexes ») synthétise les travaux antérieurs et la littérature empirique. Ici, l'objectif est de poser les concepts nécessaires et de rendre les choix de modélisation du projet explicitement interprétables.

3.1. Validation en séries temporelles et fuites d'information

3.1.1. Pourquoi la validation en séries temporelles est différente

Dans de nombreux contextes d'apprentissage automatique, les échantillons sont traités comme indépendants et identiquement distribués (i.i.d.). Les séries financières violent cette hypothèse : les observations sont ordonnées dans le temps, et les prédicteurs construits (moyennes glissantes, volatilité glissante, rendements cumulés) reposent sur des fenêtres d'historique qui se chevauchent. Si les exemples sont mélangés aléatoirement lors de l'évaluation, le modèle peut exploiter indirectement de l'information future, ou subir une contamination entraînement–test via le prétraitement. Ces effets peuvent gonfler les métriques de performance et conduire à des conclusions invalides.

Dans ce mémoire, on appelle « fuite d'information » (**leakage**) tout mécanisme par lequel de l'information située hors de la fenêtre d'entraînement influence les décisions d'entraînement ou les représentations apprises. Trois canaux de fuite sont particulièrement pertinents :

- **Fuite via le découpage (split leakage) :** les données d'entraînement incluent des dates postérieures à celles du test.
- **Fuite via le prétraitement (preprocessing leakage) :** des transformations (p. ex. la standardisation) sont ajustées en utilisant de l'information provenant des périodes de validation/test.
- **Fuite liée à l'horizon du label (label-horizon leakage) :** les labels dépendent de valeurs futures (p. ex. à $t + k$) ; ainsi, des observations proches d'une frontière temporelle peuvent avoir des labels calculés à partir de prix appartenant à un bloc ultérieur.

3.1.2. Schémas de validation utilisés dans ce mémoire (V1 et V2)

Deux schémas d'évaluation respectant l'ordre temporel sont utilisés :

- **V1 (holdout chronologique) :** un découpage train/validation/test unique par blocs temporels contigus.
- **V2 (walk-forward, fenêtre croissante) :** plusieurs plis où l'entraînement s'étend dans le temps et où le test est effectué sur des blocs futurs successifs.

V1 répond à la question : « Si l'on entraîne une seule fois sur l'historique initial, quelle est la performance sur des périodes ultérieures ? ». V2 répond à : « Les conclusions sont-elles stables sur plusieurs fenêtres hors-échantillon successives ? ».

Schéma	Segment/Pli	Train début	Train fin	n train	Test/Val début	Test/Val fin	n test/val
V1	Train	2000-01-03	2015-12-31	4169	—	—	—
V1	Validation	—	—	—	2016-01-01	2019-12-31	1043
V1	Test	—	—	—	2020-01-01	2025-11-25	1540
V2	F1	2000-01-03	2009-12-31	2604	2010-01-01	2011-12-30	521
V2	F2	2000-01-03	2011-12-30	3125	2012-01-02	2013-12-31	522
V2	F3	2000-01-03	2013-12-31	3647	2014-01-01	2015-12-31	522
V2	F4	2000-01-03	2015-12-31	4169	2016-01-01	2019-12-31	1043

Tableau 1 — Fenêtres de validation (V1 et V2)

3.1.3. Contrôles anti-leakage utilisés dans ce projet

Le protocole expérimental utilise trois garde-fous concrets :

(A) Prétraitement entraînement-seulement. Toute transformation estimant des paramètres à partir des données (p. ex. moyenne et variance pour la standardisation) est ajustée uniquement sur la partie d'entraînement de chaque split/pli, puis appliquée à validation/test sans ré-ajustement. Cela empêche l'information future sur la distribution d'influencer les représentations apprises à l'entraînement.

(B) Alignement local à la fenêtre et gestion locale des valeurs manquantes. L'alignement features/labels et le filtrage des valeurs manquantes (NaN) sont effectués à l'intérieur de chaque fenêtre (split/pli), après restriction par dates. Cela évite les effets de « filtrage global », où l'ensemble des échantillons conservés en entraînement dépendrait de la présence (ou non) de périodes ultérieures.

(C) Anti-circularité pour les labels définis par indicateurs. Pour les labels L2 (définis par indicateurs), un mode d'échec survient lorsque les features incluent directement les mêmes indicateurs que ceux qui définissent le label (p. ex. termes de croisement de moyennes mobiles). La classification peut alors se réduire à reproduire la règle d'étiquetage plutôt qu'à apprendre une relation plus générale. Les expériences principales L2 imposent donc une contrainte d'anti-circularité : les features qui encodent directement la règle L2 (p. ex. croisement MA et pente de la MA lente) sont exclues du **core** de modélisation.

3.1.4. Fuite de frontière pour les labels à horizon futur (limitation documentée)

Dans le pipeline exécuté, ce canal est traité par une purge explicite : pour toute fenêtre d'entraînement (V1 train et train de chaque pli V2), les $k = 5$ dernières dates de la fenêtre d'entraînement sont supprimées avant l'apprentissage, de sorte que, pour tout échantillon conservé en entraînement, l'horizon $t + 5$ demeure strictement inclus dans la fenêtre d'entraînement. Ainsi, le risque de recouvrement d'horizon aux frontières est bloqué pour l'entraînement dans les expériences L1 ; les blocs de validation/test restent inchangés.

3.2. Stratégies d'étiquetage (labels) en finance

3.2.1. Les labels définissent le problème d'apprentissage

Un classifieur supervisé de régimes apprend un mapping $x_t \to y_t$, où x_t est un vecteur de features dérivé des prix historiques et y_t un label de régime discret. En classification de régimes financiers, les labels sont généralement **construits** plutôt qu'observés. Des définitions différentes des labels codent des hypothèses différentes sur ce qu'est un « régime » (mouvement futur vs état de tendance présent), ce qui affecte directement la capacité d'apprentissage, l'équilibre des classes et l'interprétabilité.

Ce mémoire utilise trois classes ordonnées :

$$\{-1, 0, +1\} \equiv \{\text{down}, \text{neutral}, \text{up}\}.$$

Deux familles de labels sont comparées :

- **L1 (labels à rendement futur) :** régimes définis par des rendements log futurs à k jours ($k = 5$).
- **L2 (labels à indicateurs) :** régimes définis par la structure de moyennes mobiles et une pente de MA lente, calculées à partir de l'historique.

3.2.2. L1_Q : régimes par quantiles du rendement futur ($k = 5$)

Soit P_t le prix de clôture et $\ell_t = \log(P_t)$. On définit le rendement log futur à l'horizon k par :

$$R_t^{(k)} = \ell_{t+k} - \ell_t = \log\left(\frac{P_{t+k}}{P_t}\right), \quad k = 5.$$

L1_Q calcule des seuils de quantiles sur la période d'entraînement :

$$\tau_{\text{low}} = Q_{0.2}\left(R_t^{(5)}\right), \quad \tau_{\text{high}} = Q_{0.8}\left(R_t^{(5)}\right),$$

puis assigne :

$$y_t = \begin{cases} -1 \text{ si } R_t^{(5)} < \tau_{\text{low}} \\ +1 \text{ si } R_t^{(5)} > \tau_{\text{high}} \\ 0 \quad \text{sinon.} \end{cases}$$

Cette construction impose une séparation queues/centre (par définition sur l'entraînement). Elle est à horizon futur et hérite donc du problème de frontière décrit en Section 3.1.4.

3.2.3. L1_extreme : régimes à seuil volatilité-scalé ($k = 5$, $\lambda = 0.75$)

L1_extreme est une variante de sensibilité qui remplace les quantiles par un seuil proportionnel à la volatilité. En utilisant le même $R_t^{(5)}$, on définit :

$$\theta = \lambda * \sigma_{\text{train}} * \sqrt{5},$$

où σ_{train} est l'écart-type des rendements log journaliers calculé sur la période d'entraînement uniquement, et $\lambda = 0.75$. La règle d'étiquetage est :

$$y_t = \begin{cases} +1 \text{ si } R_t^{(5)} > \theta \\ -1 \text{ si } R_t^{(5)} < -\theta \\ 0 \quad \text{sinon.} \end{cases}$$

3.2.4. L2 : croisement de moyennes mobiles avec filtre de pente MA lente (MA10/MA50, $h = 5$)

L2 définit les régimes à partir du log-prix via deux moyennes mobiles et un filtre de pente dérivé de la moyenne mobile lente.

Soit $\ell_t = \log(P_t)$. On définit :

- Moyenne mobile rapide :

$$\text{MA}_{\text{fast}}(t) = \text{mean}(\ell_{t-9}, ..., \ell_t) \quad \text{(fenêtre 10, min periods 10)}$$

- Moyenne mobile lente :

$$\text{MA}_{\text{slow}}(t) = \text{mean}(\ell_{t-49}, ..., \ell_t) \quad \text{(fenêtre 50, min periods 50)}$$

- Proxy de pente (différence retardée) sur $h = 5$:

$$S(t) = \mathrm{MA}_{\text{slow}}(t) - \mathrm{MA}_{\text{slow}}(t-h), \quad h = 5.$$

Le mapping des labels est :

$$y_t = \begin{cases} +1 \text{ si } \mathrm{MA}_{\text{fast}}(t) > \mathrm{MA}_{\text{slow}}(t) \wedge S(t) > 0 \\ -1 \text{ si } \mathrm{MA}_{\text{fast}}(t) < \mathrm{MA}_{\text{slow}}(t) \wedge S(t) < 0 \\ 0 \quad \text{sinon.} \end{cases}$$

Si $\mathrm{MA}_{\text{slow}}(t)$ ou $S(t)$ est indéfini par manque d'historique, alors y_t est indéfini (NaN). Cela crée une zone de warm-up au début de chaque fenêtre temporelle, supprimée lors de l'alignement local.

Note sur le timing de prédiction. Dans les expériences principales, le vecteur de features x_t est restreint à l'information disponible jusqu'à $t-1$ (Section 3.2.5). Par conséquent, prédire y_t impose un décalage d'un jour par rapport à toute composante du label qui dépend de ℓ_t. Il s'agit d'une contrainte intentionnelle « pas de look-ahead same-day », appliquée de manière cohérente à tous les schémas de validation.

3.2.5. Alignement causal des features (information disponible jusqu'à $t-1$)

Pour préserver une évaluation causale, les features à la date t sont définies de façon à dépendre uniquement de l'information disponible à (ou avant) $t-1$. Cela évite les effets de look-ahead le jour même et rend le protocole de validation pertinent comme proxy de déploiement. Cette contrainte est appliquée de manière cohérente dans tous les schémas de validation.

3.3. Métriques de performance (Accuracy, Macro-F1)

La classification de régimes est évaluée comme un problème à trois classes sur $\{-1, 0, +1\}$. Un enjeu pratique majeur est le déséquilibre des classes et l'effondrement vers une classe unique (p. ex. un modèle qui prédit un seul régime). C'est pourquoi l'évaluation rapporte à la fois une métrique globale (accuracy) et une métrique équilibrée (Macro-F1), ainsi que des matrices de confusion.

3.3.1. Conventions pour les matrices de confusion et ordre des classes

Les matrices de confusion comptent le nombre d'échantillons pour chaque paire (vrai, prédit). Pour garantir une interprétation cohérente d'une expérience à l'autre, on utilise l'ordre fixe :

$$[-1, 0, +1].$$

3.3.2. Accuracy

L'accuracy est la fraction d'étiquettes correctement prédites :

$$\mathrm{Acc} = \left(\frac{1}{n}\right) * \sum_{i=1}^{n} 1\{\hat{y}_i = y_i\}.$$

Elle est simple à interpréter mais peut être trompeuse lorsqu'une classe domine.

3.3.3. Précision, rappel, F1 et Macro-F1

Pour chaque classe $c \in \{-1, 0, +1\}$, on note TP_c, FP_c et FN_c les vrais positifs, faux positifs et faux négatifs de la classe c. Alors :

$$\mathrm{Prec}_c = \frac{\mathrm{TP}_c}{\mathrm{TP}_c + \mathrm{FP}_c}, \quad \mathrm{Rec}_c = \frac{\mathrm{TP}_c}{\mathrm{TP}_c + \mathrm{FN}_c},$$

$$\mathrm{F1}_c = \frac{2 * \mathrm{Prec}_c * \mathrm{Rec}_c}{\mathrm{Prec}_c + \mathrm{Rec}_c}.$$

La Macro-F1 moyenne les F1 des classes de manière uniforme :

$$\text{MacroF1} = \left(\frac{1}{3}\right) * \sum_{\{c \in \{-1,0,+1\}\}} \text{F1}_c.$$

La Macro-F1 pénalise directement les prédicteurs dégénérés qui ignorent un ou plusieurs régimes.

3.3.4. Gestion déterministe des valeurs indéfinies lorsqu'une classe n'est jamais prédite

Si un modèle ne prédit jamais une classe dans un bloc d'évaluation, certains termes de précision et de rappel deviennent indéfinis (division par zéro). La procédure d'évaluation traite ce cas de manière déterministe en fixant ces scores indéfinis à zéro (équivalent à `zero_division = 0`). Ainsi, la Macro-F1 reflète explicitement le comportement « classe manquante » comme un mode d'échec, plutôt que de le masquer par une convention implicite.

3.4. Résumé des implications méthodologiques clés

- V1 et V2 respectent l'ordre temporel et évitent la fuite directe via le découpage ; V2 fournit plusieurs tests successifs hors-échantillon.
- Les labels L1 sont à horizon futur avec $k = 5$; afin d'éviter tout recouvrement d'horizon à une frontière de split, une purge de frontière est appliquée sur chaque fenêtre d'entraînement (suppression des $k = 5$ dernières dates avant apprentissage), tandis que les fenêtres de validation/test restent inchangées.
- Les labels L2 sont définis par indicateurs (MA10/MA50 avec pente MA lente $h = 5$) et nécessitent une phase de warm-up produisant des NaN, supprimés lors de l'alignement local.
- L'accuracy est rapportée mais peut masquer un effondrement ; la Macro-F1 et les matrices de confusion fournissent des diagnostics équilibrés, avec un traitement déterministe des métriques indéfinies par classe.

4. Travaux connexes

Ce chapitre passe en revue les travaux antérieurs qui éclairent le cadrage méthodologique de ce mémoire pour la classification supervisée de régimes de marché sur des séries temporelles financières. Il ne s'agit pas d'une enquête exhaustive sur les modèles économétriques de régimes, ni d'une comparaison de type **leaderboard** fondée sur la précision prédictive. L'accent est plutôt mis sur deux choix méthodologiques qui déterminent largement la crédibilité en **financial ML** : (i) la manière dont les régimes sont opérationnalisés sous forme de labels, et (ii) la conception de l'évaluation en présence de dépendance temporelle et de risque de fuite d'information (**leakage**). Ce choix est cohérent avec l'objectif du mémoire : produire des enseignements méthodologiques même lorsque la performance prédictive demeure limitée.

La revue est structurée en quatre axes : (1) les notions de régime et les principales traditions de modélisation, (2) l'intérêt de baselines volontairement simples — régression logistique et SVM linéaire — comme points de comparaison contrôlés, (3) les protocoles d'évaluation adaptés aux séries temporelles ainsi que les canaux de fuite d'information, et (4) les choix d'étiquetage susceptibles de dominer l'interprétation des résultats.

4.1. Régimes de marché : définitions et traditions de modélisation

On appelle généralement **régime de marché** un état relativement persistant du processus générateur des données financières, au sein duquel la distribution des rendements — et, plus largement, des quantités associées (volatilité, tendance, corrélations) — présente des caractéristiques stables, avant de changer au fil du temps. Dans la pratique, ces régimes sont souvent décrits de manière qualitative (marché **bull/bear/sideways**, phases **risk-on/risk-off**, épisodes d'expansion ou de contraction de volatilité).

Dans la tradition économétrique, les régimes sont souvent modélisés comme des états latents plutôt que comme des classes directement observées. Une approche canonique est le changement de régime markovien (**Markov regime switching**), où les paramètres d'un processus observé dépendent d'un état discret non observé qui évolue selon un mécanisme de transition

markovien. La formulation de Hamilton est largement citée comme fondation pour modéliser le changement structurel sous forme de dynamiques dépendantes de l'état, plutôt que comme un unique processus stationnaire. [2]

Cette perspective reste pertinente lorsqu'on adopte une classification supervisée. En contexte supervisé, un « régime » n'est généralement pas une vérité terrain observée de l'extérieur ; il doit être opérationnalisé. Les approches économétriques infèrent des régimes latents à partir des données, tandis que les approches supervisées définissent un label de régime par une règle explicite et apprennent à prédire cette règle. Cela déplace la question scientifique de la **découverte de régimes** vers la **prédiction de l'accord avec une définition spécifiée du régime**, ce qui fait de la construction des labels une partie intégrante de la méthode plutôt qu'une étape de prétraitement supposée neutre.

Implication pour ce mémoire. Les performances rapportées doivent être lues à la lumière de la définition retenue pour le régime : changer la règle d'étiquetage revient à changer la cible d'apprentissage. Pour cette raison, les choix d'étiquetage sont explicités, justifiés et considérés comme un axe expérimental à part entière.

4.2. Baselines linéaires pour la classification de régimes en données limitées

Les séries financières combinent dépendance temporelle, non-stationnarité et, dès qu'on impose une évaluation strictement hors-échantillon, une réduction de la taille effective des jeux d'entraînement. Dans ce cadre, des modèles linéaires volontairement simples constituent un point de départ pertinent : ils se régularisent facilement, se comportent de manière relativement stable, et fournissent une référence transparente. L'objectif n'est pas de maximiser la performance, mais d'utiliser ces baselines comme instrument de contrôle pour attribuer les effets observés aux choix méthodologiques — en particulier la définition des labels et le schéma de validation.

4.2.1. Machines à vecteurs de support (SVM)

Les machines à vecteurs de support (SVM) ont été largement utilisées dans des cadres de classification financière avec des jeux de variables construits, leur capacité étant contrôlée via la maximisation de la marge et la régularisation. Des études appliquées précoces ont utilisé les SVM pour la prédiction de mouvements de marché et les ont comparées à d'autres apprenants disponibles à l'époque (p. ex., Kim, 2003 ; Huang et al., 2005). [3], [4] Ces travaux sont surtout pertinents ici comme **précédent** justifiant l'usage des SVM comme baselines en classification financière, plutôt que comme garantie d'une transférabilité des performances entre marchés ou jeux de données.

Implication pour ce mémoire. Les SVM fournissent une baseline défendable lorsque l'objectif est de mettre à l'épreuve les définitions de labels et les protocoles d'évaluation sous des contraintes respectant le temps.

4.2.2. Régression logistique

La régression logistique constitue une baseline standard en raison de sa simplicité, de sa stabilité sous régularisation, et de son interprétation probabiliste. Elle s'étend naturellement à la classification multi-classe via la régression logistique multinomiale, compatible avec des sorties discrètes de type « états/régimes ». Par exemple, Hsu utilise une formulation **multinomial logit** avec plusieurs catégories d'états de marché (bull vs deux types de bear), illustrant comment la classification de régimes peut être formulée comme une prédiction probabiliste multi-états. [5]

Implication pour ce mémoire. La régression logistique est utile à la fois comme classifieur de référence et comme outil de diagnostic : lorsque la performance se dégrade, des causes comme le déséquilibre de classes, le bruit de labels ou des fuites dans l'évaluation sont souvent plus interprétables qu'avec des modèles de capacité plus élevée.

4.3. Méthodologie de validation pour données financières dépendantes temporellement

4.3.1. Pourquoi la validation i.i.d. est invalide par défaut

La validation croisée standard en k-plis suppose que les échantillons sont échangeables (i.i.d.), ce qui est généralement faux pour les séries temporelles financières. Le mélange aléatoire peut contaminer l'évaluation en permettant à l'entraînement d'utiliser des informations temporellement futures par rapport au test, ou en réutilisant des fenêtres qui se recouvrent dans les variables et les cibles. Bergmeir & Benítez discutent de la validation croisée pour séries temporelles et motivent des alternatives respectant le temps (p. ex., procédures par blocs ou roulantes) pour la sélection de modèles et l'estimation des performances. [6]

Une alternative fréquemment utilisée est l'évaluation à origine roulante (**rolling-origin evaluation**), où le modèle est ré-estimé de manière répétée sur les données jusqu'à un instant donné, puis évalué sur des observations ultérieures, avant d'agréger les erreurs sur plusieurs origines. Cette procédure est décrite dans des références standard en prévision et s'aligne conceptuellement avec un déploiement réel, où seules les données passées sont disponibles au moment de la prédiction. [7]

Implication pour ce mémoire. Pour les séries temporelles, l'évaluation fait partie de la méthode : préserver l'ordre temporel est une condition nécessaire pour obtenir des estimations **out-of-sample** crédibles.

4.3.2. Évaluation walk-forward et outillage

L'évaluation **walk-forward** (fenêtre roulante ou croissante) est très utilisée en finance appliquée, car elle produit plusieurs tests **out-of-sample** et peut révéler une instabilité en situation de non-stationnarité. Les outils pratiques reflètent ce besoin : scikit-learn fournit `TimeSeriesSplit`, qui impose un ordre chronologique dans les découpages et empêche l'entraînement sur des observations futures par rapport aux plis de test. [8] Toutefois, un découpage chronologique ne suffit pas à éliminer automatiquement tous les canaux de fuite (p. ex. recouvrement induit par des horizons de labels ou prétraitements globaux). Ces canaux doivent être traités explicitement au niveau du pipeline.

Implication pour ce mémoire. L'évaluation **walk-forward** agit à la fois comme garde-fou et comme test de résistance à la non-stationnarité, mais elle doit être accompagnée de contrôles explicites contre les fuites.

4.3.3. Fuite au-delà de « train après test » : recouvrement, purge et embargo

Même avec des splits chronologiques, des fuites peuvent persister via le recouvrement. Deux sources courantes sont : (i) les fenêtres de variables qui se chevauchent, et (ii) les cibles orientées futur (p. ex. rendements forward à horizon fixe) qui créent une dépendance entre échantillons adjacents à une frontière de split. Dans la méthodologie **practitioner-oriented** du **financial ML**, López de Prado formalise la purge (**purging**, suppression des échantillons d'entraînement dont l'information chevauche la période de test) et l'embargo (introduction d'un intervalle tampon) comme contrôles explicites réduisant la contamination. [9], [10]

Implication pour ce mémoire. Un « split chronologique » est nécessaire mais non suffisant ; des fuites peuvent se produire via les horizons et les recouvrements si elles ne sont pas traitées explicitement.

4.3.4. Tests multiples et surapprentissage des backtests

Un second risque pour la validité tient à la multiplicité. Dès lors que l'on explore de nombreuses stratégies, variantes de labels, ensembles de variables ou réglages d'hyperparamètres, le fait de retenir a posteriori "le meilleur" backtest peut produire une estimation artificiellement optimiste — y compris lorsque l'évaluation est présentée comme **out-of-sample**. Bailey, Borwein, López de Prado et Zhu formalisent ce phénomène via la **probability of backtest overfitting (PBO)** et montrent que le biais de sélection devient d'autant plus préoccupant que l'espace de recherche est large au regard de la taille effective d'échantillon. [11] Des travaux plus récents discutent également la conception des tests **out-of-sample** et son interaction avec le risque de surapprentissage dans des backtests guidés par des modèles de ML. [12]

Implication pour ce mémoire. Le protocole retient volontairement un périmètre expérimental étroit (familles de modèles limitées, hyperparamètres figés, schémas V1/V2 strictement temporels). L'objectif est de réduire les degrés de liberté et de privilégier la crédibilité des conclusions plutôt que l'optimisation des performances **in-sample**.

4.4. Construction des labels de régimes financiers et pièges courants

Dans la classification supervisée de régimes, les labels définissent le problème d'apprentissage. Contrairement à des domaines où les labels correspondent à des catégories observées de l'extérieur, les labels de « régime » en finance sont souvent construits à partir de la même série de prix utilisée pour les variables. En conséquence, la conception des labels peut dominer l'apprenabilité, l'équilibre des classes et l'interprétation.

4.4.1. Labels à horizon fixe basés sur le rendement

Une approche courante consiste à étiqueter chaque instant selon le signe ou la magnitude seuillée d'un rendement futur sur un horizon fixe. Cela confère une sémantique claire, liée à un mouvement réalisé sur un horizon donné. Structurellement, cela introduit aussi une dépendance orientée futur et une sensibilité aux frontières, en particulier près des limites de split, sauf si l'alignement et des contrôles de fuite sont appliqués.

Implication pour ce mémoire. Les labels à horizon de rendement sont simples à définir mais exigent un traitement explicite des frontières et une évaluation consciente des fuites.

4.4.2. Labels de tendance et fragmentation

Des schémas d'étiquetage visant à réduire la fragmentation cherchent à préserver la continuité des tendances. Wu et al. proposent un étiquetage continu de tendance et montrent que modifier la définition du label peut changer substantiellement les résultats de classification. [13] Le point méthodologique est que le choix du label modifie la tâche, donc la conception des labels doit être traitée comme un axe expérimental plutôt que comme une étape implicite de prétraitement.

Implication pour ce mémoire. Comparer des familles de labels est scientifiquement pertinent, car les définitions de labels peuvent dominer les résultats.

4.4.3. Labels basés sur des événements et sémantique économique

L'étiquetage basé sur des événements définit les sorties via des événements de franchissement de barrières (p. ex. prise de profit ou stop-loss) dans une période maximale de détention ; la méthode des trois barrières (**triple-barrier**) en est un exemple marquant. [9] Bien que l'étiquetage par événements ne soit pas identique à l'étiquetage par régimes, il renforce un

principe général : les labels encodent des hypothèses de modélisation sur ce qui constitue un mouvement significatif.

Implication pour ce mémoire. Pour les labels définis par indicateurs, il est indispensable de vérifier explicitement l'absence de recouvrement direct entre la règle d'étiquetage et les variables d'entrée, afin d'éviter des solutions purement tautologiques.

4.4.4. Contexte : marchés moins étudiés ou données limitées

La littérature empirique en **financial ML** porte majoritairement sur des marchés profonds et liquides ; les conclusions et les bonnes pratiques ne se transposent pas toujours telles quelles lorsque la taille effective d'échantillon est réduite et que des changements structurels sont plausibles. Des travaux appliquant des approches de ML à des contextes moins étudiés (par exemple certains marchés africains) soulignent que, lorsque les données sont limitées, la qualité du protocole d'évaluation et la discipline méthodologique pèsent autant que le choix du modèle. [14], [15]

Implication pour ce mémoire. Dans un contexte à données limitées, la rigueur méthodologique — en particulier sur l'étiquetage et la validation temporelle — constitue un garde-fou prioritaire pour soutenir des conclusions crédibles.

4.5. Synthèse : leçons méthodologiques motivant ce mémoire

La littérature soutient trois leçons méthodologiques qui motivent une étude prudente de classification de régimes sur séries temporelles financières :

1. Les régimes doivent être opérationnalisés. Qu'il s'agisse de modèles à états latents ou de labels supervisés, un « régime » est une construction de modélisation ; en supervisé, la définition du label fait partie de la méthode.
2. La validation doit respecter le temps et verrouiller les canaux de fuite. Un simple découpage chronologique ne suffit pas dès lors que des labels à horizon, des fenêtres glissantes ou des étapes de prétraitement peuvent transférer indirectement de l'information à travers une frontière train–test.
3. Les degrés de liberté doivent être limités pour réduire les fausses découvertes. Multiplier les variantes et retenir a posteriori la meilleure combinaison (modèle, label, stratégie) augmente le risque de conclusions sur-optimistes ; un design expérimental volontairement conservateur améliore la crédibilité. [11]

Dans ce contexte, recourir à des baselines linéaires (régression logistique, SVM linéaire) est méthodologiquement défendable : ces modèles servent de référence transparente et contrôlée pour attribuer les effets observés aux choix de labels et au schéma d'évaluation, plutôt qu'à une forte capacité de modélisation.

5. Données et prétraitement

Ce chapitre définit le contrat de données (data contract) commun à toutes les expériences du mémoire : la provenance de la série MRU/USD, les étapes de prétraitement déterministes utilisées pour construire le jeu de données OHLC canonique en jours ouvrés, ainsi que les contrôles d'intégrité qui en établissent les invariants (unicité des dates, tri temporel, et absence de valeurs OHLC manquantes). Ces engagements figent précisément les entrées à partir desquelles les labels, les features et les découpages de validation sont ensuite calculés, ce qui garantit l'auditabilité et la reproductibilité.

5.1. Sources de données et justification de la sélection

5.1.1. Série principale

La série modélisée est une série quotidienne MRU/USD issue d'un export Investing.com, puis consolidée dans un unique fichier brut.

- Instrument : MRU pour 1 USD (MRU/USD).
- Artefact brut principal : `merged_all_days.csv`.
- Justification : parmi les fournisseurs examinés, cet export offre l'historique le plus long et le plus continu, ce qui est compatible avec l'objectif d'une étude de cas contrôlée sur la période 2000–2025.

Lors de la phase d'audit, la série brute a été comparée de manière qualitative à une référence externe (WFP) sur des périodes de recouvrement, afin de vérifier la plausibilité des niveaux et des variations (direction). D'autres fournisseurs ont également été sondés pour évaluer la faisabilité d'un horizon de modélisation couvrant 2000–2025.

5.1.2. Sources alternatives considérées (sanity-check uniquement)

Des sources alternatives ont été examinées mais non retenues comme série principale, pour des raisons de couverture et de cohérence :

- Banque Centrale de Mauritanie (BCM) : couverture courte (2024–2025) et faible densité d'observations ; des écarts de niveau par rapport aux séries Investing/WFP ont été observés, compatibles avec des différences de définition du taux et/ou de convention de fixing.

Yahoo Finance / Google Finance : historique limité (environ à partir de 2016) et valeurs incohérentes selon les fournisseurs.

Décision : le mémoire utilise la série dérivée d'Investing.com comme jeu de données de modélisation principal et conserve les sources alternatives uniquement pour des vérifications de plausibilité sur des périodes de recouvrement limitées.

5.2. Structure du jeu de données brut et audit des valeurs manquantes

5.2.1. Structure du fichier brut

Le jeu de données brut merged_all_days.csv est construit sur un index calendaire complet :

Plage de dates : 2000-01-01 à 2025-11-25 (inclus).

Lignes : 9 461 (une ligne par jour calendaire).

Intégrité du calendrier : dates strictement triées ; aucune date dupliquée ; aucun jour manquant (c.-à-d. aucune lacune « no-row »).

L'export brut contient des champs spécifiques au fournisseur (p. ex. colonnes de style et doublons numériques). Les champs clés pour la modélisation sont les prix OHLC et la colonne temporelle utilisée pour l'indexation.

5.2.2. Disponibilité des OHLC et « jours sans prix »

Un constat central de l'audit est que le jeu de données brut inclut de nombreuses lignes correspondant à des jours calendaires sans valeurs OHLC exploitables (« empty-price placeholders »). Sur l'ensemble de la période 2000–2025 :

Jours avec au moins une valeur OHLC observée (au moins l'un de Open/High/Low/Close présent) : 8 241

Jours avec une ligne mais OHLC entièrement manquants : 1 220

Jours sans ligne : 0

Les jours sans prix sont quasi exclusivement des week-ends :

Jours de week-end sans prix (samedi/dimanche) : 1 215

Jours de semaine sans prix (lun–ven) : 5

Cela indique que le mécanisme de valeurs manquantes dominant provient du traitement des week-ends par le fournisseur (lignes vides et/ou artefacts), plutôt que de lacunes généralisées sur les jours ouvrés. En conséquence, traiter la série comme une série régulière à 5 jours (« trading-week ») constitue un choix de prétraitement naturel et réduit substantiellement les artefacts liés au calendrier.

5.2.3. Qualité des colonnes et décisions de conservation

Le fichier brut contient des champs qui ne sont pas fiables ou pas pertinents pour la modélisation :

Volume est peu renseigné et est exclu du jeu de données de modélisation.

Les champs cosmétiques spécifiques au fournisseur (p. ex. direction_color) sont exclus.

Les doublons numériques (p. ex. last_*Raw) sont exclus au profit d'un unique ensemble OHLC cohérent.

Pour rendre la transformation explicite et reproductible, le Tableau 2 documente le mapping brut ⟶ nettoyé utilisé pour le schéma OHLC canonique.

Colonne brute	Colonne nettoyée
`last_open`	`open`
`last_max`	`high`
`last_min`	`low`
`last_close`	`close`

Tableau 2 — Correspondance colonnes brutes ⟶ colonnes nettoyées (OHLC)

Le jeu de données nettoyé conserve uniquement le schéma minimal robuste requis par les expériences du mémoire : un index canonique date et les colonnes OHLC.

5.3. Construction de la série OHLC nettoyée

5.3.1. Objectifs du nettoyage

Le prétraitement vise à produire un jeu de données déterministe et auditable qui :

ne contient que des dates avec des observations de prix exploitables,

utilise un calendrier cohérent en jours ouvrés adapté à une modélisation « trading-day »,

fournit un schéma OHLC minimal utilisé par la construction des labels et des features,

rend explicites les valeurs manquantes et les effets de warm-up (plutôt que d'imputer).

5.3.2. Règles de nettoyage

Le jeu de données nettoyé est construit à partir de l'export brut selon les règles suivantes :

Parser la colonne temporelle brute en une colonne date canonique (datetime).

Retirer toute ligne où l'un des champs OHLC (open, high, low, close) est manquant, afin de ne conserver que des observations complètes.

Filtrer la série aux jours ouvrés (lundi–vendredi) pour éliminer les lignes de week-end vides et les artefacts liés au calendrier.

Sélectionner puis renommer les colonnes essentielles selon un schéma OHLC canonique :

- `date` (datetime)
- `open`, `high`, `low`, `close` (float)

Contrôler les invariants du jeu de données nettoyé :

- dates strictement croissantes,
- absence de doublons de date,
- absence de valeurs manquantes dans les colonnes OHLC.

Sauvegarder le jeu de données nettoyé comme entrée canonique de modélisation :

mru_usd_ohlc_clean.csv

5.3.3. Résumé du jeu de données nettoyé (contrat de données)

Le jeu de données utilisé dans tout le mémoire satisfait les propriétés attestées suivantes :

Propriété	Valeur
Artefact canonique	`mru_usd_ohlc_clean.csv` (`data/processed/`)
Lignes (N)	6 752
Plage de dates	2000-01-03 à 2025-11-25
Calendrier	Jours ouvrés uniquement (lun–ven).
Unicité des dates	6 752 dates distinctes (aucun doublon).
Ordre	Strictement croissant par date.
Valeurs manquantes	0 valeurs manquantes dans `open/high/low/close`.
Schéma	`date` (datetime64[ns]), `open/high/low/high/close` (float64).

Tableau 3 — Résumé du jeu OHLC nettoyé (contrat de données)

La répartition par jour de semaine est globalement homogène sur l'ensemble de la période : les écarts entre jours restent faibles (de l'ordre de 1 à 2 journées), ce qui correspond à ce que l'on attend d'un long historique limité aux jours ouvrés.

5.4. Séries dérivées pour l'analyse en aval

Le mémoire utilise des quantités dérivées calculées à partir de la série OHLC nettoyée afin de soutenir l'inspection exploratoire et de fournir des briques standard utilisées ultérieurement lors de l'étiquetage et de l'ingénierie des features. Toutes les variables dérivées sont construites via des opérations causales (rétrospectives) sur la série en jours ouvrés.

5.4.1. Rendements

Deux variantes standard de rendements journaliers sont calculées à partir du prix de clôture P_t :

Rendement logarithmique

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right).$$

Rendement simple

$$s_t = \frac{P_t - P_{t-1}}{P_{t-1}}.$$

Les deux dépendent de P_{t-1} ; ainsi, la première observation a un rendement indéfini et est représentée par une unique valeur NaN initiale. Les statistiques de synthèse des rendements ne sont pas nécessaires pour définir le contrat de données ; lorsqu'elles sont rapportées, elles sont traitées comme descriptives plutôt que comme des résultats de modélisation.

5.4.2. Volatilité glissante (30 jours et 90 jours)

La volatilité glissante est calculée comme l'écart-type glissant des rendements log :

Volatilité 30 jours

$$\sigma_{30}(t) = \mathrm{std}(r_{t-29}, ..., r_t).$$

Volatilité 90 jours

$$\sigma_{90}(t) = \mathrm{std}(r_{t-89}, ..., r_t).$$

Ces fenêtres glissantes introduisent des régions de warm-up déterministes (NaN initiaux), attendues et non imputées. Les pipelines en aval gèrent ce warm-up en effectuant un alignement local (par split/pli) après restriction par dates (voir le chapitre de protocole expérimental).

5.4.3. Artefact dérivé sauvegardé

Un artefact de volatilité glissante est sauvegardé pour réutilisation :

Artefact : mru_usd_rolling_volatility.csv

Colonnes : date, vol_30, vol_90

Cet artefact soutient l'analyse exploratoire et le développement méthodologique, mais n'est pas une cible de modélisation.

5.5. Périmètre et limites du prétraitement

5.5.1. Périmètre et non-objectifs

Le prétraitement est volontairement conservateur :

Aucune interpolation ni imputation n'est appliquée aux OHLC manquants dans le jeu brut.

Les lignes de week-end sont supprimées afin d'éliminer le comportement spécifique du fournisseur sur les week-ends et d'obtenir un calendrier de modélisation cohérent en jours ouvrés.

Seul le schéma OHLC est conservé ; les champs à sémantique incertaine ou à couverture insuffisante (p. ex. volume) sont exclus.

5.5.2. Dépendance au fournisseur et comparabilité

Le jeu de données de modélisation repose sur un unique export d'un fournisseur principal. Bien que des sources alternatives aient été consultées à titre de **sanity-check** sur des périodes de recouvrement limitées, elles ne sont pas retenues pour l'entraînement, principalement en raison d'une couverture insuffisante et de définitions non parfaitement comparables. En pratique, le jeu nettoyé doit donc être compris comme la série OHLC MRU/USD en jours ouvrés dérivée d'Investing.com via un filtrage déterministe ; toute conclusion formulée dans le mémoire est conditionnelle à ce choix de source et au processus de préparation associé.

5.5.3. Interprétation du calendrier et effets de warm-up

Le filtrage des week-ends remplace un index calendaire par un index de type **trading-day** (jours ouvrés uniquement). Ce choix est cohérent avec le protocole de modélisation, mais il doit être pris en compte dès qu'un horizon est exprimé en « jours de trading ». Par ailleurs, les constructions à fenêtre glissante génèrent des NaN de **warm-up** au début de chaque bloc contigu ; ces lignes sont ensuite éliminées par l'alignement et le filtrage locaux des features et des labels, appliqués séparément dans chaque fenêtre d'évaluation après restriction par dates.

6. Conception des labels

6.1. Ouverture du chapitre

En apprentissage automatique supervisé appliqué à la finance (financial ML), les labels sont rarement « donnés » : ils sont construits à partir de la même série temporelle que celle utilisée pour les features. La conception des labels fait donc partie intégrante de la méthode expérimentale : elle définit ce que le modèle doit prédire, façonne l'équilibre des classes et contraint ce qui constitue une évaluation valide respectant la temporalité. Dans ce mémoire, la conception des labels est ainsi traitée comme un axe expérimental de premier ordre, au même titre que le protocole de validation.

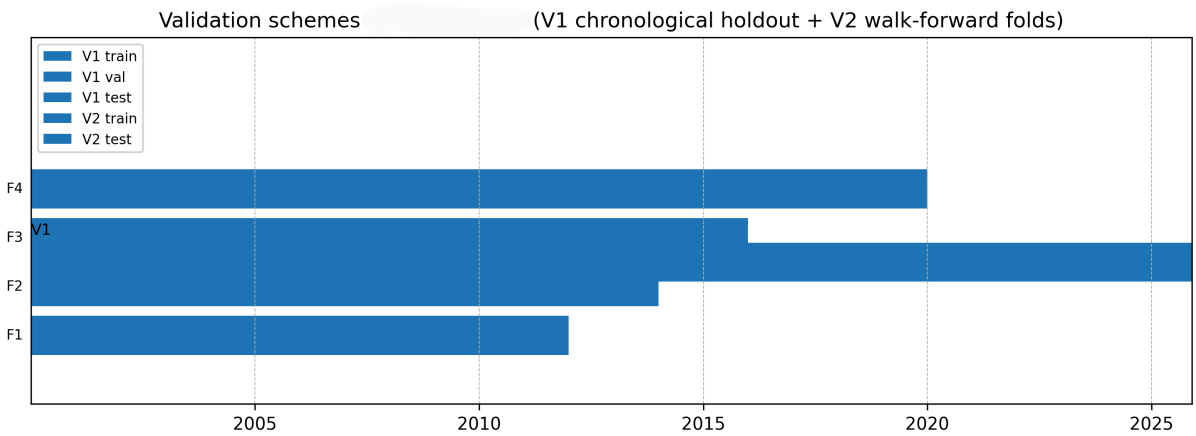

Fig. 1 — Chronologie de validation (V1 holdout et plis V2 walk-forward).

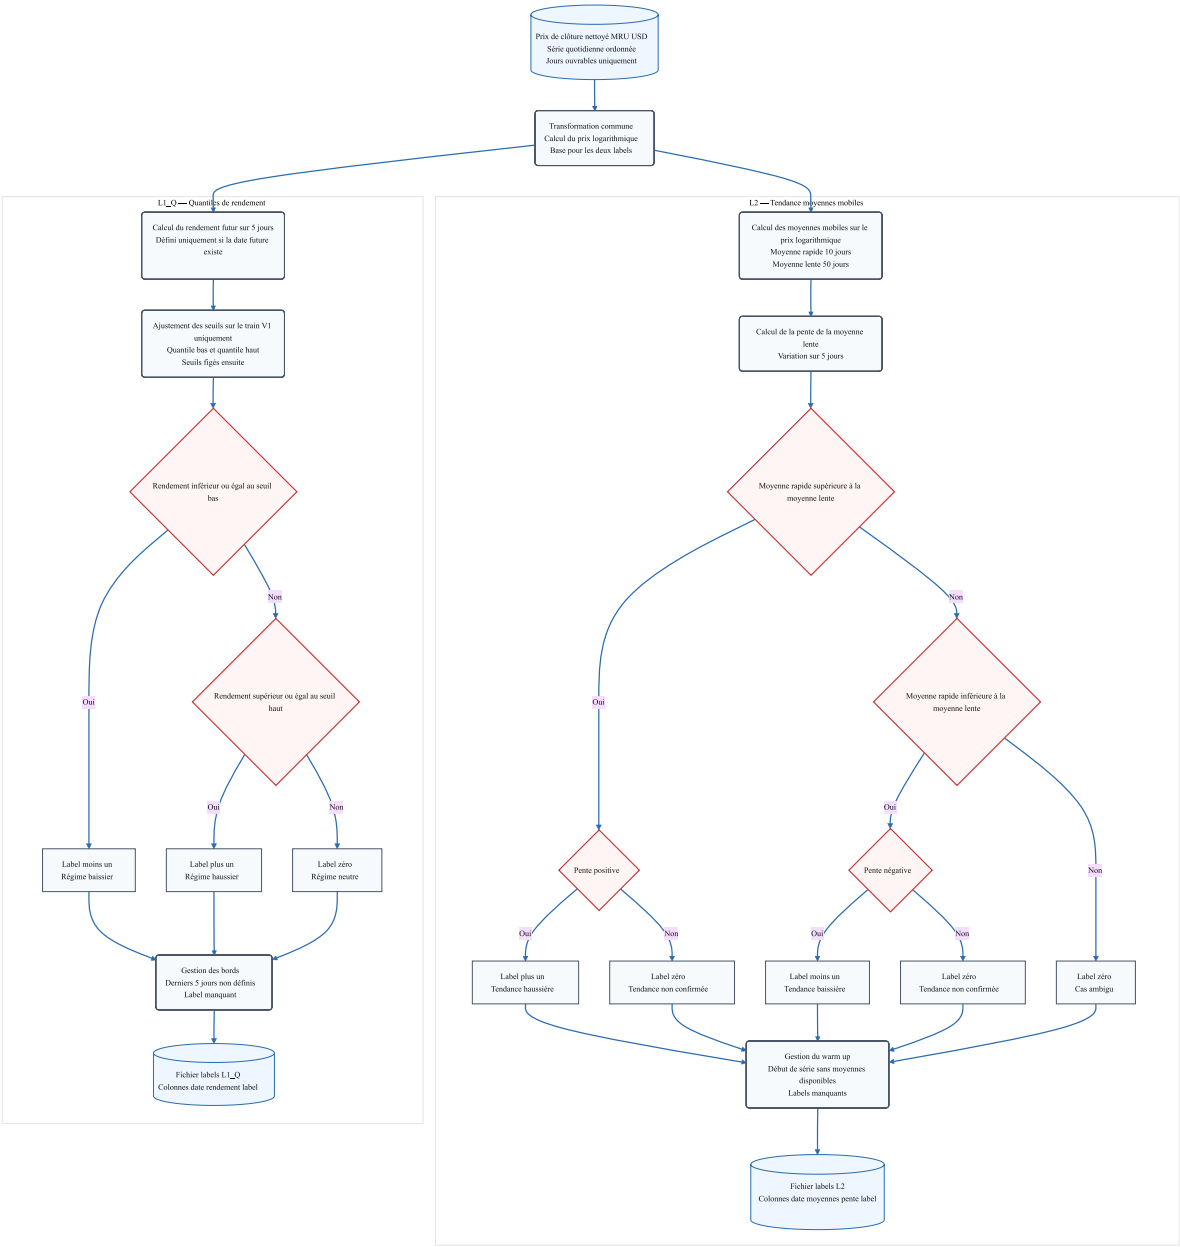

Fig. 2 — Génération des labels : (L1) rendements futurs à horizon k=5 puis application de seuils ; (L2) indicateurs MA10/MA50 et filtre de pente puis affectation de la classe −1/0/+1.

6.2. Définition des labels fondés sur le rendement (L1)

6.2.1. Cible de rendement futur et horizon

Soit P_t le prix de clôture au jour de trading t, et définissons la série des log-prix par $\ell_t = \log(P_t)$. La famille L1 définit un rendement log futur (forward) sur un horizon fixe de $k = 5$ jours de trading :

Rendement futur : $R_t^5 = \ell_{t+5} - \ell_t = \log\left(\frac{P(t+5)}{P_t}\right)$.

Il s'agit d'une construction orientée futur : le label à la date t utilise la clôture future P_{t+5}. Par conséquent, les $k = 5$ dernières dates de toute fenêtre temporelle contiguë ne peuvent pas être étiquetées (valeurs indéfinies dues au décalage d'horizon).

6.2.2. L1_Q (seuils par quantiles) et période d'ajustement des seuils

L'instanciation de référence L1 utilisée dans le pipeline principal est L1_Q, qui projette R_t^5 sur trois régimes $\{-1, 0, +1\}$ via deux seuils de quantiles.

Horizon : $k = 5$

Découpage en queues : 20% | 60% | 20% (c.-à-d. $q_{\text{low}} = 0.2$, $q_{\text{high}} = 0.8$)

Les seuils sont calculés uniquement sur l'intervalle d'entraînement V1, puis appliqués pour étiqueter l'ensemble du jeu de données.

Formellement, soient τ_{low} et τ_{high} les quantiles 0.2 et 0.8 de R_t^5 estimés sur l'intervalle d'entraînement V1. Alors :

$y_t = -1$ si $R_t^5 < \tau(\text{low})$

$y_t = +1$ si $R_t^5 > \tau(\text{high})$

$y_t = 0$ sinon.

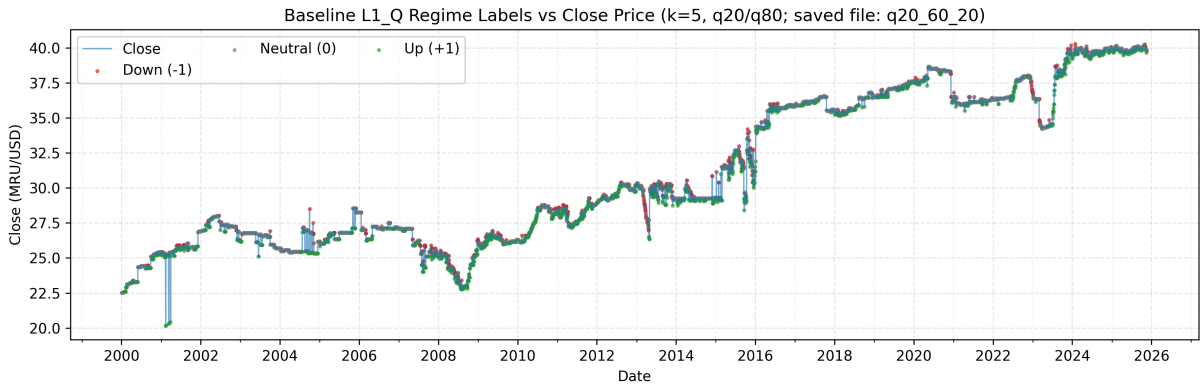

Fig. 3 — Régimes L1_Q superposés au prix de clôture (sanity check de la définition L1).

6.2.3. Variante L1 documentée : L1_extreme (seuil mis à l'échelle par la volatilité)

Une seconde variante L1 est définie comme construction de sensibilité (L1_extreme) : elle remplace les quantiles par un seuil symétrique, mis à l'échelle par la volatilité :

$$\theta = \lambda * \sigma_{\text{train}} * \sqrt{5}, \quad \lambda = 0.75,$$

où σ_{train} est l'écart-type des rendements log journaliers calculé sur la période d'entraînement.

6.2.4. Timing/disponibilité et considérations de frontière en évaluation

Comme y_t dépend de P_{t+5}, le label à la date t n'est pas disponible à la date t dans un cadre de déploiement réel. En évaluation, cette dépendance futur impose deux contraintes concrètes :

Zone indéfinie en fin de fenêtre : les $k = 5$ dernières dates de tout bloc contigu ne sont pas étiquetées par construction.

Risque de recouvrement aux frontières (label-horizon overlap) : si une fenêtre d'entraînement se termine à la date t, les labels pour des dates proches de t dépendent de prix postérieurs à t. Dans le pipeline exécuté, ce canal est bloqué par une purge explicite : pour toute fenêtre d'entraînement (V1 train et train de chaque pli V2), les $k = 5$ dernières dates de la fenêtre d'entraînement sont supprimées avant l'apprentissage, de sorte que, pour tout échantillon conservé en entraînement, l'horizon $t + 5$ demeure strictement inclus dans la fenêtre d'entraînement. Les fenêtres de validation/test restent inchangées.

6.3. Définition des labels fondés sur des indicateurs (L2)

6.3.1. Indicateurs et paramètres

L2 définit les régimes à partir de la structure historique du log-prix via un croisement de moyennes mobiles, complété par un filtre de pente sur la moyenne mobile lente. La configuration enregistrée fixe :

fenêtre MA rapide : 10

fenêtre MA lente : 50

retard de pente : $h = 5$

Soit $\ell_t = \log(P_t)$. On définit :

$\mathrm{MA}_{\text{fast}}(t)$: moyenne glissante de ℓ_t sur les 10 dernières observations

$\mathrm{MA}_{\text{slow}}(t)$: moyenne glissante de ℓ_t sur les 50 dernières observations

proxy de pente : $S(t) = \mathrm{MA}_{\text{slow}}(t) - \mathrm{MA}_{\text{slow}}(t-h)$ avec $h = 5$.

6.3.2. Mapping exact à trois classes

Le mapping des régimes L2 est défini par la règle suivante :

$$y_t = \begin{cases} +1 \text{ si } \mathrm{MA}_{\text{fast}}(t) > \mathrm{MA}_{\text{slow}}(t) \wedge \mathrm{S}(t) > 0 \\ -1 \text{ si } \mathrm{MA}_{\text{fast}}(t) < \mathrm{MA}_{\text{slow}}(t) \wedge \mathrm{S}(t) < 0 \\ 0 \quad \text{sinon.} \end{cases}$$

6.3.3. Zone de warm-up, labels indéfinis et traitement des lignes

L2 requiert un historique suffisant pour $\mathrm{MA}_{\mathrm{slow}}(t)$ et $S(t)$. Si ces quantités sont indéfinies, le label est indéfini (NaN). Dans les expériences, l'alignement features/labels et la suppression des NaN sont réalisés à l'intérieur de chaque fenêtre split/pli après restriction par dates ; les effets de warm-up réduisent donc la taille effective d'échantillon utilisée à l'entraînement.

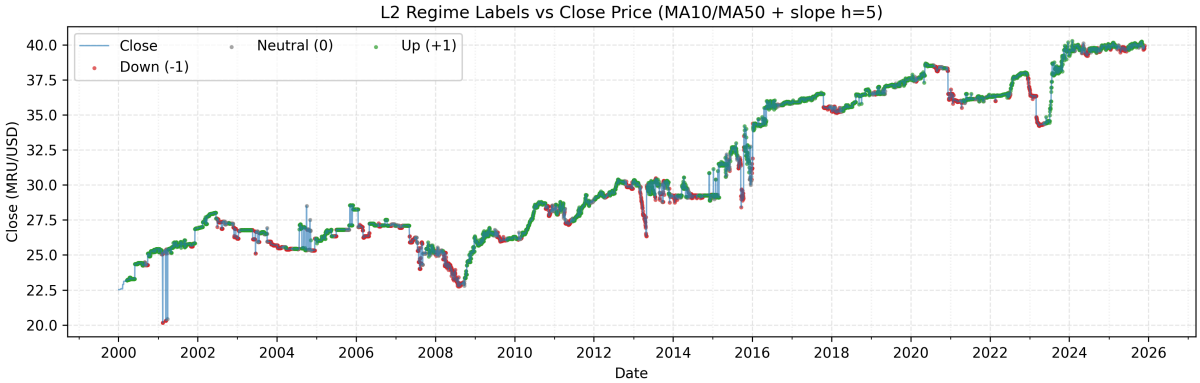

Fig. 4 — Régimes L2 superposés au prix de clôture (sanity check de la définition L2).

6.3.4. Risque de circularité et atténuation par exclusion de features

Les labels fondés sur des indicateurs exposent un risque de circularité : si les variables d'entrée contiennent les mêmes indicateurs que ceux utilisés pour construire le label (ou une transformation algébriquement équivalente), le modèle peut se limiter à reconstruire la règle d'étiquetage au lieu d'apprendre une relation réellement généralisable. Pour les expériences principales sur L2, le protocole impose donc une contrainte explicite : les features qui codent directement la règle L2 (par exemple les termes de croisement MA et la pente de la moyenne mobile lente) sont exclues du core de modélisation.

6.4. Distributions de classes pour L1 vs L2

Comme les labels sont construits, leurs proportions de classes font partie de la méthode : elles affectent la difficulté effective de la tâche de classification et l'interprétation des métriques agrégées.

6.4.1. Distributions globales (résumé label-only)

Les artefacts du mémoire contiennent le résumé suivant des distributions globales sur l'ensemble de la série en jours ouvrés (incluant les labels indéfinis).

Label	Classe	Effectif	Part de 6752
L1 (L1_Q)	−1	1340	19.85%
	0	4073	60.32%
	+1	1334	19.76%
	NaN	5	0.07%
L2	−1	2008	29.74%
	0	1127	16.69%
	+1	3567	52.83%
	NaN	50	0.74%

Tableau 4 — Distribution globale des labels (label-only, y compris NaN)

Sous ce résumé, L1_Q produit globalement une majorité de régime neutre, tandis que L2 produit une majorité de régime haussier avec une part neutre plus faible.

6.4.2. Distributions globales (table de modélisation fusionnée utilisée dans les expériences)

Les artefacts du projet contiennent également une distribution globale calculée sur la table de modélisation fusionnée utilisée en aval (après jointure des labels avec la table de modélisation utilisée dans les expériences). Dans cette table fusionnée, les effectifs globaux sont :

Label	Classe	Effectif	Part de 6752
L1 (L1_Q)	−1	1129	16.72%
	0	4442	65.79%
	+1	1176	17.42%
	NaN	5	0.07%
L2	−1	2013	29.82%
	0	1223	18.11%
	+1	3462	51.27%
	NaN	54	0.80%

Tableau 5 — Distribution globale des labels (table fusionnée, y compris NaN)

Ces totaux diffèrent du Tableau 4. Dans tout le mémoire, je rapporte donc les deux : (i) la distribution label-only sur la série complète en jours ouvrés, et (ii) la distribution sur la table de modélisation fusionnée utilisée dans les expériences.

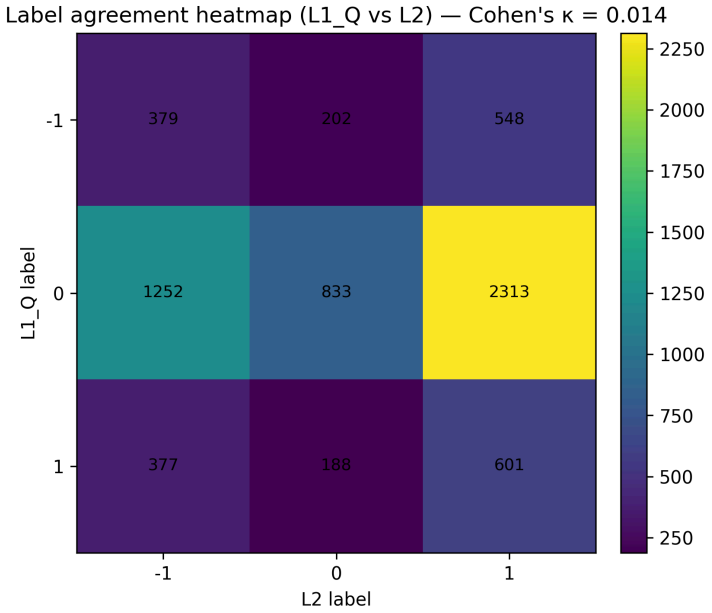

Fig. 5 — Accord entre familles de labels (L1_Q vs L2) — heatmap sur la chronologie commune.

6.4.3. Distributions V1 après alignement local par segment (échantillons effectifs)

Comme les expériences retirent les lignes avec NaN après restriction à chaque fenêtre d'évaluation, l'équilibre de classes pertinent pour la modélisation correspond à la distribution sur les échantillons post-filtrés.

L1_Q — segments V1

Segment	n	−1 (down)	0 (neutral)	+1 (up)
train	4138	834 (20.15%)	2475 (59.81%)	829 (20.03%)
val	1043	87 (8.34%)	820 (78.62%)	136 (13.04%)
test	1535	208 (13.55%)	1123 (73.16%)	204 (13.29%)

Tableau 6 — Équilibre des classes V1 (L1_Q, après alignement/filtrage NaN)

L2 — segments V1

Segment	n	−1 (down)	0 (neutral)	+1 (up)
train	4115	1409 (34.24%)	767 (18.64%)	1939 (47.12%)
val	1043	147 (14.09%)	188 (18.02%)	708 (67.88%)
test	1540	457 (29.68%)	268 (17.40%)	815 (52.92%)

Tableau 7 — Équilibre des classes V1 (L2, après alignement/filtrage NaN)

6.4.4. Distributions des fenêtres de test V2 par pli (dérivées des totaux de lignes des matrices de confusion)

Pour l'évaluation walk-forward, l'équilibre par pli peut être reconstruit à partir des matrices de confusion rapportées (les totaux de lignes correspondent aux effectifs par classe vraie dans chaque fenêtre de test).

L1_Q — fenêtres de test V2

Pli (fenêtre test)	n	−1 (down)	0 (neutral)	+1 (up)
F1	521	88 (16.89%)	260 (49.90%)	173 (33.21%)
F2	522	161 (30.84%)	258 (49.43%)	103 (19.73%)
F3	522	149 (28.54%)	247 (47.32%)	126 (24.14%)
F4	1043	87 (8.34%)	820 (78.62%)	136 (13.04%)

Tableau 8 — Équilibre des classes V2 par pli (L1_Q, fenêtres test)

L2 — fenêtres de test V2

Pli (fenêtre test)	n	−1 (down)	0 (neutral)	+1 (up)
F1	521	126 (24.18%)	94 (18.04%)	301 (57.77%)
F2	522	177 (33.91%)	77 (14.75%)	268 (51.34%)
F3	522	173 (33.14%)	121 (23.18%)	228 (43.68%)
F4	1043	147 (14.09%)	188 (18.02%)	708 (67.88%)

Tableau 9 — Équilibre des classes V2 par pli (L2, fenêtres test)

6.5. Contrat de reproductibilité pour l'alignement labels–features

Afin de rendre la conception des labels auditables, les expériences appliquent une politique d'alignement déterministe : (i) labels et features sont joints par date, (ii) l'alignement et le filtrage des NaN sont effectués à l'intérieur de chaque fenêtre split/pli après restriction par dates, et (iii) tout prétraitement estimant des paramètres à partir des données (p. ex. mise à l'échelle des features) est ajusté uniquement sur la portion d'entraînement, puis appliqué aux segments/plis ultérieurs sans ré-ajustement. Cela garantit que les tailles effectives d'échantillon et les distributions de classes rapportées en Section 6.4 sont reproductibles à partir des artefacts stockés, sous les mêmes définitions de fenêtres.

6.6. Résumé du chapitre

Ce chapitre a défini deux schémas d'étiquetage des régimes utilisés dans tout le mémoire : L1_Q (régimes fondés sur un rendement log futur à horizon $k = 5$ avec seuils de quantiles ajustés sur l'intervalle d'entraînement V1) et L2 (croisement de moyennes mobiles avec filtre de pente de MA lente). Les contraintes de disponibilité des labels ont également été rendues explicites (zones indéfinies de fin de fenêtre dues à l'horizon futur pour L1, zones de warm-up indéfinies pour L2) et les distributions de classes ont été rapportées pour les deux familles, à la fois globalement et au sein des fenêtres d'évaluation V1/V2. Ces distributions ne sont pas accessoires : elles font partie de la méthode et conditionnent directement l'interprétation des résultats de classification présentés dans les chapitres suivants.

7. Jeu de features et configuration des modèles

Ce chapitre spécifie le contrat de features et la configuration des modèles utilisés dans l'ensemble des expériences supervisées de classification de régimes. L'objectif de conception est un apprentissage contrôlé et auditables : un bloc de features compact, calculé sous une règle stricte sans look-ahead le jour même (no same-day look-ahead), associé à des classifieurs linéaires simples dont les réglages sont figés afin de minimiser les degrés de liberté. Cette contrainte est volontaire : elle maintient les comparaisons centrées sur la conception des labels (L1 vs. L2) et le protocole de validation (V1 vs. V2), plutôt que sur une sélection extensive de modèles.

7.1. Features cœur (F_CORE)

7.1.1. Entrées et notations

Toutes les features implémentées sont dérivées uniquement du prix de clôture. Soit P_t la clôture au jour t. On définit :

$$\ell_t = \log(P_t), \quad r_t = \ell_t - \ell_{t-1}.$$

7.1.2. Règle de timing de l'information (alignement causal)

Afin de préserver une évaluation causale, les features à l'instant t sont définies pour ne dépendre que de l'information disponible jusqu'à $t-1$:

$$x_t \ \text{ dépendre uniquement de } \ \{\ell_{t-1}, \ell_{t-2}, \ldots\} \ \text{ et } \ \{r_{t-1}, r_{t-2}, \ldots\}.$$

En termes d'implémentation, cette contrainte est imposée par un décalage explicite (p. ex. shift(1)) avant le calcul des statistiques glissantes ou des différences de retards, garantissant que la clôture du jour courant n'entre pas dans le vecteur de features aligné sur ce même jour.

Tous les indices de retard suivent la convention d'implémentation : t est la date de prédiction ; les features se terminent à $t-1$.

7.1.3. Définition exacte de F_CORE

Les expériences principales utilisent un bloc cœur de 5 features, défini explicitement :

$$\text{F_CORE} = [\text{f_r_lag1}, \text{f_past_ret_5}, \text{f_past_ret_20}, \text{f_vol_10}, \text{f_vol_30}].$$

Feature	Définition implémentée au temps t	Fenêtre / paramètres	Données utilisées
`f_r_lag1`	r_{t-1}	—	$t-1$
`f_past_ret_5`	$\ell_{t-1} - \ell_{t-5}$	lag-diff	$t-1$
`f_past_ret_20`	$\ell_{t-1} - \ell_{t-20}$	lag-diff	$t-1$
`f_vol_10`	$\mathrm{Std}(r_{t-10}, \ldots, r_{t-1})$	rolling std, 10 (min 10)	$t-1$
`f_vol_30`	$\mathrm{Std}(r_{t-30}, \ldots, r_{t-1})$	rolling std, 30 (min 30)	$t-1$

Tableau 10 — Définitions des features cœur et timing.

7.1.4. Warm-up et gestion des NaN

Du fait de l'inclusion de termes retardés et de termes glissants, la partie initiale de toute fenêtre temporelle contiguë contient des NaN de warm-up déterministes. De plus, les labels peuvent être indéfinis dans certaines zones d'une fenêtre (p. ex. effets de frontière en fin de fenêtre pour L1, ou warm-up d'indicateurs pour L2). Le pipeline applique une règle unique et explicite :

« Après restriction de chaque fenêtre split/pli par dates, supprimer toute ligne contenant un NaN dans (colonnes de features sélectionnées ∪ colonne de label). »

Cette règle est appliquée de manière cohérente en V1 (train/val/test) et en V2 (train-pli/test-pli), garantissant que les modèles sont entraînés uniquement sur des lignes où x_t et y_t sont bien définis sous les contraintes de timing adoptées.

7.2. Features additionnelles (définies mais exclues des baselines)

En plus de F_CORE, des features additionnelles sont définies pour l'analyse diagnostique. Elles ne sont pas employées dans les expériences de référence (E1–E8), lesquelles utilisent uniquement F_CORE pour l'entraînement

7.2.1. Features de niveau à base de moyennes mobiles (définies, hors F_CORE)

Deux features optionnelles basées sur des niveaux sont définies à partir du log-prix retardé, afin de rester causales vis-à-vis de $t-1$:

$$\text{f_ma_50}(t) = \left(\frac{1}{50}\right) * \sum_{i=1}^{50} \ell_{t-i}, \quad \text{f_dist_50}(t) = \ell_{t-1} - \text{f_ma_50}(t).$$

7.2.2. Indicateur de forte volatilité (défini, calibré sur train)

Un indicateur binaire optionnel f_high_vol est défini par seuillage de la volatilité à court horizon :

$$\text{f_high_vol}(t) = 1[\text{f_vol_10}(t) > q_{0.7}(\text{f_vol_10} \quad \text{on} \quad \text{V1-train})].$$

Le seuil est calibré uniquement sur V1-train (ajustement sur train uniquement). La valeur de seuil enregistrée est $q_{0.7} = 0.005555$.

7.2.3. Anti-circularité pour L2 (séparation features–label)

L2 est défini par une structure de moyennes mobiles et un filtre basé sur la pente. Si le jeu de features incluait les mêmes indicateurs (ou des signaux algébriquement équivalents), le classifieur pourrait reconstruire trivialement la règle d'étiquetage. Par conséquent, les expériences L2 principales imposent une contrainte d'anti-circularité : les features qui encodent directement la règle L2 sont exclues du jeu de features core de modélisation. En pratique, les baselines L2 utilisent uniquement F_CORE.

7.3. Choix des modèles (Régression logistique, SVM linéaire)

Le mémoire utilise deux familles de modèles linéaires comme baselines contrôlées :

Régression logistique multiclasse,

SVM linéaire via LinearSVC.

L'objectif est de conserver une capacité de modèle volontairement limitée et un comportement facilement interprétable, afin que les différences observées soient attribuées, autant que possible, à la définition des labels et au protocole de validation plutôt qu'à la puissance du modèle.

7.3.1. Contrôle de reproductibilité (convention de seed)

Convention de seed. Dès le début du projet, la constante `random_state = 42` est utilisée partout où elle est supportée, afin de permettre des relances reproductibles. Cette valeur est fixée par convention et n'a pas fait l'objet d'un ajustement.

7.3.2. Hyperparamètres figés par conception

Les hyperparamètres sont maintenus identiques d'une expérience à l'autre et ne sont pas optimisés. Ce choix méthodologique vise à limiter les degrés de liberté et à isoler l'effet de trois facteurs :

- la construction des labels (L1 vs L2),
- le schéma de validation (V1 vs V2),
- la famille de modèles (régression logistique vs SVM linéaire),

plutôt que de chercher à maximiser la performance prédictive via une recherche d'hyperparamètres. Chaque configuration est exécutée une seule fois avec ces réglages figés (pas de tuning, pas de balayage de seeds).

7.3.3. Configurations figées

Régression logistique (V1) :

penalty=« l2 », solver=« lbfgs », C=1.0 multi_class=« auto », max_iter=1000 class_weight=None, random_state=42

Régression logistique (V2) :

penalty=« l2 », solver=« lbfgs », C=1.0 multi_class=« multinomial », max_iter=200 class_weight=None, random_state=42

SVM linéaire (V1, LinearSVC) :

C=1.0, max_iter=5000 class_weight=None, random_state=42

SVM linéaire (V2, LinearSVC) :

C=1.0, max_iter=2000 class_weight=None, random_state=42

Pondération des classes. Les expériences de base rapportées dans ce mémoire utilisent class_weight=None afin de conserver une baseline strictement contrôlée. À titre de vérification de robustesse, une exécution auxiliaire avec class_weight=‹ balanced › a été testée ; elle ne modifie pas qualitativement les modes de défaillance observés (collapse / classe neutre rarement ou jamais prédite) et n'est donc pas détaillée ici.

7.4. Protocole d'entraînement (alignement, mise à l'échelle, et "plomberie" d'évaluation)

7.4.1. Alignement local à la fenêtre et filtrage

Dans chaque fenêtre d'évaluation (un segment V1 ou un pli V2), features et labels sont alignés par date, puis filtrés via la règle NaN décrite en Section 7.1.4. Cela garantit que le warm-up est géré localement à chaque split/pli et ne dépend pas de périodes futures.

7.4.2. Mise à l'échelle (ajustement sur l'entraînement uniquement)

Tous les modèles utilisent des features standardisées via `StandardScaler`, avec une règle stricte **train-only** :

- V1 : le scaler est ajusté sur le bloc V1-train, puis appliqué tel quel à V1-val et V1-test.
- V2 : le scaler est ajusté sur le bloc d'entraînement de chaque pli, puis appliqué tel quel au bloc de test correspondant.

Cette procédure empêche qu'une information issue des périodes validation/test influence, même indirectement, les représentations apprises à l'entraînement.

7.4.3. Métriques et sorties de diagnostic

L'évaluation suit une logique « diagnostic d'abord » (Chapitre 4) :

- Accuracy et Macro-F1,
- précision / rappel / F1 par classe pour ({−1, 0, +1}),
- matrices de confusion selon l'ordre fixe ([−1, 0, +1]),
- traitement déterministe des scores indéfinis via `zero_division = 0`.

7.5. Contrôles de fuite et de circularité

7.5.1. Prévention du look-ahead côté features (implémenté)

La contrainte causale $t - 1$ est imposée directement dans la construction des features via des décalages explicites et des calculs glissants sur des séries retardées. Par conséquent, x_t n'inclut pas d'information de clôture du jour même.

7.5.2. Prévention de la circularité L2 (implémenté)

Pour L2, les features qui encodent la règle de label sont exclues du jeu de features baseline de modélisation, et les baselines L2 reposent sur F_CORE.

7.5.3. Fuite de frontière pour les labels L1 à horizon futur (limitation documentée)

Les labels L1 dépendent de P_{t+5} , de sorte que des labels proches de la fin d'une fenêtre peuvent référencer des prix situés hors de cette fenêtre. Aucune étape additionnelle de type purge/embargo aux frontières internes des splits n'est enregistrée dans le pipeline tel qu'exécuté ; le recouvrement de frontière demeure donc une menace à la validité pour les expériences basées sur L1.

Par ailleurs, une fuite de ce type irait plutôt dans le sens d'une surestimation des performances. Elle ne peut donc pas rendre compte du mode d'échec observé dans les expériences L1 (effondrement vers la classe neutre) ; si elle existait, elle renforcerait au contraire l'exigence de prudence dans la lecture des résultats L1.

7.6. Résumé du chapitre

Ce chapitre a fixé les contrats de features et de modèles appliqués dans l'ensemble du mémoire. Les expériences de base reposent sur un bloc de variables compact, construit uniquement à partir de la clôture (F_CORE) et calculé de manière strictement causale (information disponible jusqu'à (t-1)), sur une standardisation **train-only**, et sur des baselines linéaires à réglages figés (régression logistique et SVM linéaire). Le protocole retient également l'absence de pondération des classes et une convention de seed au niveau du projet (`random_state = 42`) afin de garantir la reproductibilité. Enfin, des blocs de features additionnels sont documentés mais exclus des baselines, et les expériences L2 imposent une contrainte explicite d'anti-circularité pour éviter toute reconstruction triviale de labels définis par indicateurs.

8. Protocole expérimental

Ce chapitre décrit le protocole expérimental effectivement exécuté qui a servi à produire l'ensemble des résultats de classification analysés dans les chapitres suivants (classification et backtesting). Le protocole est formulé comme un ensemble de règles méthodologiques explicites : il précise (i) le partitionnement temporel des données, (ii) l'alignement features–labels, (iii) le prétraitement, puis (iv) les modalités d'évaluation et d'agrégation des sorties. L'objectif est de rendre les résultats auditables et reproductibles.

Le protocole couvre : (i) les schémas d'évaluation respectant le temps (V1 et V2), (ii) l'alignement local aux fenêtres et la gestion des valeurs manquantes, (iii) un prétraitement ajusté uniquement sur l'entraînement (**train-only**), (iv) les procédures d'entraînement et d'évaluation, (v) les règles de persistance nécessaires à la reproductibilité, et (vi) l'agrégation des résultats **walk-forward**.

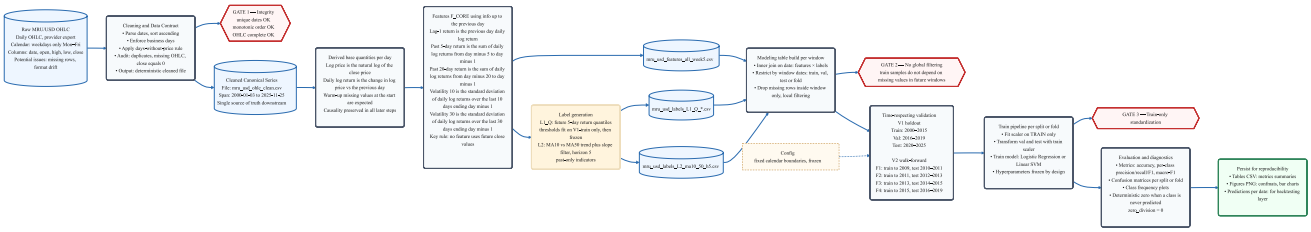

Fig. 6 — Vue d'ensemble du pipeline expérimental : données ⟶ features (alignement causal) ⟶ génération des labels ⟶ splits temporels (V1/V2) ⟶ entraînement et évaluation.

8.1. Contrats expérimentaux fixes

Toutes les expériences du mémoire respectent les contrats suivants.

- Contrat de données. La série utilisée pour la modélisation est le jeu de données MRU/USD OHLC nettoyé, limité aux jours ouvrés, couvrant la période 2000-01-03 à 2025-11-25, comprenant 6 752 observations, strictement ordonnées par date et ne contenant aucune valeur OHLC manquante.
- Contrats de labels.

  - Famille L1 (labels à rendement futur, (k = 5)). Régimes à trois classes dans ({−1, 0, +1}) dérivés du rendement logarithmique futur sur un horizon de (k = 5) jours de bourse (L1_Q, avec L1_extreme conservé comme variante de sensibilité).
  - Famille L2 (labels de tendance basés sur indicateurs). Régimes à trois classes dans ({−1, 0, +1}) définis à partir d'un croisement MA10/MA50 avec un filtre de pente de la moyenne mobile lente ((h = 5)), produisant une zone de **warm-up** déterministe avec labels indéfinis.
- Contrat de features. Les expériences de base utilisent exclusivement F_CORE et imposent une règle stricte de pas de look-ahead le jour même : les features alignées à la date (t) ne dépendent que de l'information disponible jusqu'à (t-1).
- Contrat de modèles. Deux classifieurs linéaires de référence sont utilisés de manière systématique : la régression logistique multiclasse et la machine à vecteurs de support linéaire (`LinearSVC`), avec hyperparamètres fixes et `random_state=42` lorsque applicable.
- Conventions d'évaluation.
  - Métriques : Accuracy et Macro-F1, complétées par la précision, le rappel et la F1 par classe pour les classes ([−1, 0, +1]).
  - Diagnostics : matrices de confusion rapportées selon un ordre de classes fixe ([−1, 0, +1]).
  - Les valeurs de métriques indéfinies par classe sont traitées de manière déterministe via `zero_division=0`.

8.2. Fenêtres d'évaluation respectant le temps

Deux schémas d'évaluation sont employés : un **holdout** chronologique unique (V1) et une évaluation **walk-forward** à fenêtre d'entraînement croissante (V2). Toutes les fenêtres sont contiguës, non chevauchantes et respectent strictement l'ordre temporel.

8.2.1. V1 : holdout chronologique

Le schéma V1 partitionne la chronologie en trois blocs :

- Entraînement : 2000-01-03 ⟶ 2015-12-31
- Validation : 2016-01-01 ⟶ 2019-12-31
- Test : 2020-01-01 ⟶ 2025-11-25

8.2.2. V2 : plis walk-forward à fenêtre croissante

Le schéma V2 évalue la stabilité sur plusieurs fenêtres de test successives :

- F1 : entraînement 2000-01-03 ⟶ 2009-12-31 ; test 2010-01-01 ⟶ 2011-12-30
- F2 : entraînement 2000-01-03 ⟶ 2011-12-30 ; test 2012-01-02 ⟶ 2013-12-31
- F3 : entraînement 2000-01-03 ⟶ 2013-12-31 ; test 2014-01-01 ⟶ 2015-12-31
- F4 : entraînement 2000-01-03 ⟶ 2015-12-31 ; test 2016-01-01 ⟶ 2019-12-31

Les effectifs correspondent au nombre d'observations dans chaque fenêtre avant l'alignement local aux fenêtres et le filtrage des NaN.

8.3. Alignement local aux fenêtres et gestion des valeurs manquantes

L'alignement et la gestion des valeurs manquantes sont effectués à l'intérieur de chaque fenêtre d'évaluation, après restriction par dates. Cette règle empêche tout effet de filtrage global où l'inclusion d'observations d'entraînement dépendrait de données issues de périodes ultérieures.

8.3.1. Règle d'alignement

Pour toute fenêtre W :

1. Les observations sont restreintes à l'intervalle de dates de W.
2. Les features et le label sélectionné sont alignés un-à-un par date.
3. La politique de gestion des NaN propre à la fenêtre est appliquée.

8.3.2. Politique NaN

« Après restriction d'une fenêtre par dates, toute ligne contenant un NaN dans les colonnes de features sélectionnées ou dans la colonne du label choisi est supprimée. » Cela élimine :

- les NaN de **warm-up** des features induits par les calculs à décalage et à fenêtre glissante de F_CORE,
- les NaN de **warm-up** des labels L2 dus au calcul de la MA50 et du terme de pente retardée,
- les labels L1 indéfinis près des frontières de fenêtre en raison de l'horizon futur $k = 5$.

Aucune imputation n'est réalisée.

8.4. Prétraitement et contrôles de fuite d'information

8.4.1. Causalité des features

Toutes les features alignées à la date t sont calculées exclusivement à partir de l'information disponible jusqu'à $t - 1$, ce qui empêche toute fuite de type **same-day look-ahead** via le prix de clôture.

8.4.2. Standardisation train-only

La standardisation applique une règle **train-only** stricte : les paramètres du scaler sont estimés exclusivement sur les données d'entraînement, puis réutilisés tels quels hors échantillon.

- V1 : ajustement sur le bloc V1-train, application sans ré-ajustement sur V1-val et V1-test.
- V2 : ajustement sur le bloc d'entraînement de chaque pli, application sans ré-ajustement sur le bloc de test associé.

8.4.3. Effets de frontière pour les labels à horizon futur

Les labels L1 dépendent de prix futurs à l'horizon $t + 5$. Par conséquent, les labels proches des frontières de blocs peuvent, en l'absence de précaution, incorporer de l'information située au-delà de la fin d'une fenêtre d'entraînement (recouvrement d'horizon à la frontière). Dans le pipeline exécuté, ce canal est bloqué par une purge explicite : pour toute fenêtre d'entraînement (V1 train et train de chaque pli V2), les $k = 5$ dernières dates sont retirées avant l'apprentissage, de sorte que, pour tout échantillon conservé en entraînement, l'horizon $t + 5$ demeure strictement inclus dans la fenêtre d'entraînement. Les fenêtres de test restent inchangées.

8.5. Procédures d'entraînement et d'évaluation

8.5.1. Paramètres communs

- Jeu de features : F_CORE.
- Hyperparamètres : fixes (aucun ajustement). - Ordre des classes : $[-1, 0, +1]$.
- Valeurs de métriques indéfinies : `zero_division=0`.

8.5.2. Procédure V1

Pour une définition de label et un modèle donnés :

1. Restreindre les données aux blocs d'entraînement, de validation et de test V1.
2. Appliquer l'alignement local et la politique NaN à l'intérieur de chaque bloc.
3. Ajuster le scaler sur le bloc d'entraînement et transformer tous les blocs.
4. Entraîner le modèle sur le bloc d'entraînement.
5. Évaluer les performances sur les blocs d'entraînement, de validation et de test à l'aide de la suite de métriques définie.

8.5.3. Procédure V2

Pour chaque pli F_i :

1. Restreindre les données aux blocs d'entraînement et de test du pli.
2. Appliquer l'alignement local et la politique NaN séparément dans chaque bloc.
3. Ajuster le scaler sur le bloc d'entraînement du pli et transformer le bloc de test.
4. Entraîner le modèle sur le bloc d'entraînement du pli.
5. Évaluer les performances sur le bloc de test du pli.
6. Agréger les résultats au niveau des plis comme décrit en Section 8.7.

8.6. Persistance pour la reproductibilité

Afin d'assurer la reproductibilité et l'auditabilité, un ensemble minimal et déterministe de sorties est conservé.

- Les métriques sont enregistrées pour tous les blocs évalués.
  - V1 : entraînement, validation et test.
  - V2 : blocs de test des plis et agrégats.
- Les prédictions sont conservées uniquement pour les blocs de test hors échantillon.
  - V1 : bloc de test uniquement.
  - V2 : blocs de test de chaque pli.

Élément	V1 (holdout)	V2 (walk-forward)	Finalité
Métriques	Train + Val + Test	Test des plis + agrégats	Analyse de classification
Prédictions $(y, \hat{y})$	Test uniquement	Test des plis uniquement	Diagnostics et backtesting
Matrices de confusion	Test (et diagnostics de validation sélectionnés)	Test des plis + agrégat	Analyse des erreurs par classe

Tableau 11 — Contrat de persistance.

8.7. Agrégation walk-forward

L'évaluation **walk-forward** produit plusieurs fenêtres de test hors échantillon. Les résultats sont synthétisés à l'aide de règles d'agrégation déterministes.

8.7.1. Moyenne des métriques par pli

Pour toute métrique scalaire m, le résumé principal V2 est la moyenne non pondérée sur les plis :

$$\bar{m} = \frac{1}{4} * \sum (i = 1..4, m_i)$$

8.7.2. Matrice de confusion agrégée

Une matrice de confusion globale est définie comme la somme des matrices de confusion par pli :

$$\mathrm{CM}_{\mathrm{all}} = \sum_{i=1}^{4} \mathrm{CM}_i,$$

où chaque CM_i est calculée selon l'ordre de classes fixe $[-1, 0, +1]$.

8.8. Contrôle du périmètre expérimental

Afin de limiter les degrés de liberté et de réduire le risque de multiplicité :

- les classes de modèles sont limitées à la régression logistique et au SVM linéaire,
- les hyperparamètres sont fixes,
- le jeu de features est restreint à F_CORE,
- les deux familles de labels sont évaluées sous des protocoles V1 et V2 strictement identiques.

Ce chapitre a formalisé le protocole expérimental appliqué dans tout le mémoire. L'évaluation combine un **holdout** chronologique unique (V1) et un schéma **walk-forward** à fenêtre d'entraînement croissante (V2). Dans chaque fenêtre, features et labels sont alignés par date puis filtrés selon une politique NaN locale ; le prétraitement est ajusté exclusivement sur l'entraînement (**train-only**) ; et des baselines linéaires à paramètres figés sont évaluées via l'Accuracy, la Macro-F1, des métriques par classe et des matrices de confusion, sous un ordre de classes constant.

Le protocole définit enfin les règles de persistance nécessaires aux analyses ultérieures : les métriques sont enregistrées pour tous les blocs évalués, tandis que les prédictions sont exportées uniquement pour les fenêtres de test hors échantillon. Ces sorties alimentent directement l'analyse de classification et le backtesting présentés dans les chapitres suivants.

9. Résultats de classification et diagnostics

9.1. Portée du chapitre et norme de rapport

Ce chapitre présente les résultats de classification supervisée de référence pour la prédiction des régimes MRU/USD sous le protocole respectant le temps défini au Chapitre 8. L'objectif est délibérément ciblé : mesurer la performance prédictive et diagnostiquer les modes de défaillance (déséquilibre de classe, effondrement de classe, instabilité des plis et interaction label-modèle). La validation de la stratégie de trading est reportée au Chapitre 10, qui consomme les artefacts de prédiction enregistrés produits par ces expérimentations.

Huit expériences de référence (E1–E8) sont rapportées selon une grille factorielle simple :

- Deux conceptions de labels : L1_Q (régimes fondés sur des quantiles de rendement futur) vs L2 (régimes de tendance via moyennes mobiles).
- Deux familles de modèles linéaires : régression logistique multinomiale vs SVM linéaire (`LinearSVC`).
- Deux schémas de validation : V1 (découpage chronologique unique train/val/test) vs V2 (**walk-forward** sur les plis F1–F4).

Comme l'Accuracy peut être artificiellement élevée en présence de déséquilibre de classes, la Macro-F1 est retenue comme métrique de synthèse principale, complétée par les F1 par classe et des matrices de confusion (diagnostic par classe).

9.2. Contrat expérimental commun pour E1–E8

9.2.1. Ensemble de features (F_CORE)

Toutes les expériences de base utilisent le même bloc de features à 5 dimensions :

- F_CORE = [`f_r_lag1`, `f_past_ret_5`, `f_past_ret_20`, `f_vol_10`, `f_vol_30`]

Ces features sont construites pour dépendre uniquement de l'information disponible jusqu'à t−1 (pas de look-ahead).

9.2.2. Politique NaN (filtre explicite)

Dans toutes les expériences, les lignes sont filtrées selon la règle suivante :

> SUPPRIMER toute ligne contenant un NaN dans (F_CORE ∪ {label})

Cela produit deux effets déterministes :

- Suppression de warm-up au début de la série en raison des fenêtres glissantes et de la définition des labels (visible particulièrement pour L2).
- Suppression de fin de série pour L1_Q car les rendements futurs (k=5) sont indéfinis pour les dernières dates.

9.2.3. Contrôle de fuite d'information et métriques d'évaluation

Tous les modèles utilisent :

- StandardScaler ajusté uniquement sur le segment d'entraînement, puis appliqué à la validation/test (V1) ou au test de pli (V2).
- Métriques :
  - Accuracy
  - Macro-F1 (moyenne non pondérée de F1 par classe sur les classes {−1, 0, +1})
  - Pour les rapports L2, F1 par classe est explicitement rapporté.

9.2.4. Environnement d'exécution enregistré

les versions suivantes des packages :

- scikit-learn 1.7.2
- pandas 2.3.3
- numpy 2.3.5

9.3. Disponibilité des labels et diagnostics d'équilibre des classes

9.3.1. Contrôle d'intégrité du label L2 et distribution globale

Les exécutions vérifient que la table des labels L2 s'aligne exactement avec la matrice de features sur la clé `date`, et que le jeu de données fusionné est unique et monotone dans le temps. La table fusionnée présente :

- Dimensions : (6752, 16)
- Période : 2000-01-03 ⟶ 2025-11-25
- NaN du label L2 : 54

y_L2	effectif
1.0	3462
−1.0	2013
0.0	1223
NaN	54

Tableau 12 — Distribution du label L2 sur le jeu de données fusionné (NaN inclus).

Un diagnostic au niveau des segments montre que ces NaN apparaissent dans la partie initiale de la série (**warm-up**), de sorte que le filtrage des NaN réduit la taille effective de l'échantillon d'entraînement pour les expériences L2.

9.3.2. Équilibre des classes L2 par segment V1 (après filtrage)

Après application de la politique NaN (suppression de toute ligne contenant un NaN dans F_CORE ∪ {y_L2}), les tailles d'échantillon effectives sont :

- V1 train : 4169 ⟶ 4115 (54 supprimées)
- V1 val : 1043 ⟶ 1043
- V1 test : 1540 ⟶ 1540

Segment	Observations	−1	0	+1
V1 train	4115	1409	767	1939
V1 val	1043	147	188	708
V1 test	1540	457	268	815

Tableau 13 — Effectifs des classes L2 par segment V1 utilisés pour l'entraînement/évaluation (après suppression des NaN).

9.4. Performance de test synthétique sur E1–E8 (Macro-F1 et accuracy)

Pour comparer les baselines de manière cohérente :

- V1 utilise l'unique fenêtre V1_test tenue à l'écart.
- V2 utilise la moyenne non pondérée sur les tests des plis (V2_test_mean).

Exp.	Label	Valid.	Modèle	Ligne test	Accuracy	Macro-F1
E1	L1_Q	V1	Logistic Regression	V1_test	0.731596	0.281665
E2	L1_Q	V2	Logistic Regression	V2_test_mean	0.561251	0.238155
E3	L1_Q	V1	LinearSVC	V1_test	0.731596	0.281732
E4	L1_Q	V2	LinearSVC	V2_test_mean	0.562209	0.238412
E5	L2	V1	Logistic Regression	V1_test	0.627273	0.424743
E6	L2	V1	LinearSVC	V1_test	0.616883	0.408606
E7	L2	V2	Logistic Regression	V2_test_mean	0.644413	0.437053
E8	L2	V2	LinearSVC	V2_test_mean	0.642745	0.431617

Tableau 14 — Synthèse des performances sur l'ensemble de test (accuracy et Macro-F1).

9.4.1. Interprétation

Deux tendances générales se dégagent :

- Sous L1_Q (E1–E4), la Macro-F1 demeure faible (≈0.24–0.28), ce qui est cohérent avec une performance équilibrée limitée entre classes, même lorsque l'accuracy est modérée.
- Sous L2 (E5–E8), la Macro-F1 s'améliore (≈0.41–0.44), mais des diagnostics ultérieurs montrent que cette amélioration est principalement due à la séparation de −1 vs +1, tandis que la classe neutre (0) n'est pas récupérée de manière fiable par ces baselines linéaires.

9.5. Résultats et diagnostics L1_Q (E1–E4)

9.5.1. Comportement en holdout V1 (E1 vs E3)

Sous le schéma V1, la régression logistique (E1) et le SVM linéaire (E3) produisent des performances de test quasi identiques (voir Tableau 14). Toutefois, les graphiques de diagnostic indiquent que les modèles L1_Q peuvent s'effondrer vers une prédiction neutre, dans certains segments hors échantillon, ce qui gonfle artificiellement l'accuracy tout en limitant la Macro-F1.

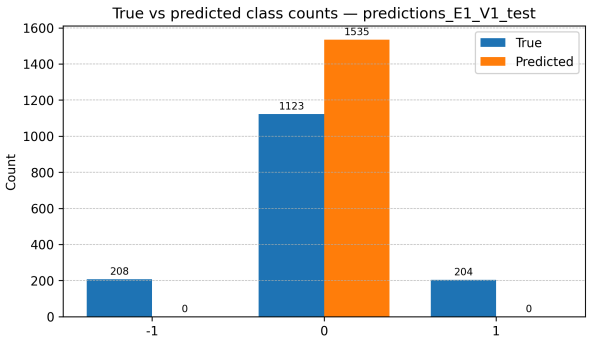

Fig. 7 — Fréquence des classes prédites L1_Q sur le test V1 (E1).

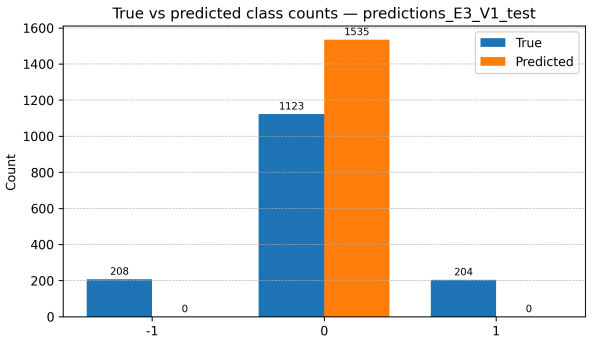

Fig. 8 — Fréquence des classes prédites L1_Q sur le test V1 (E3).

9.5.2. Comportement walk-forward V2 (E2 vs E4)

Sous le schéma V2, la performance moyenne en test est inférieure à celle observée sous V1 (voir Tableau 14). Les graphiques de fréquence des classes prédites, agrégés sur l'ensemble des tests des plis, offrent une vue synthétique de la distribution des prédictions entre les classes sur plusieurs blocs historiques successifs.

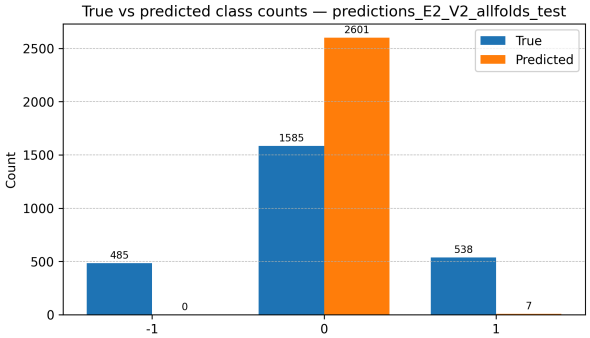

Fig. 9 — Fréquence des classes prédites L1_Q agrégée sur les tests des plis V2 (E2).

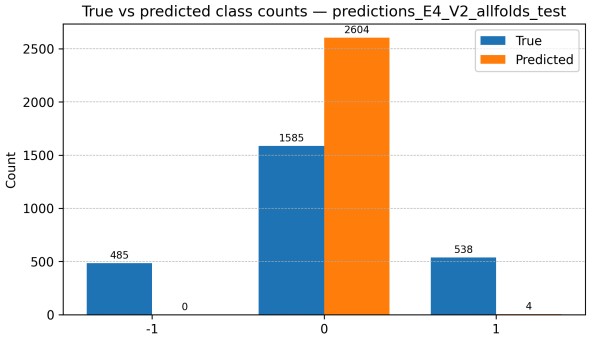

Fig. 10 — Fréquence des classes prédites L1_Q agrégée sur les tests des plis V2 (E4).

Conclusion diagnostique (L1_Q). Avec les baselines linéaires (F_CORE, sans pondération des classes), la classification L1_Q montre une séparation des régimes peu stable d'un bloc temporel à l'autre. Les diagnostics révèlent notamment des phases où les prédictions se rabattent massivement sur la classe neutre, ce qui peut préserver une accuracy correcte tout en dégradant nettement la Macro-F1.

9.6. Résultats et diagnostics L2 (E5–E8)

9.6.1. Métriques V1 (E5 vs E6)

Pour L2, le reporting inclut l'accuracy, la Macro-F1 ainsi que la F1 par classe. Contrairement à L1_Q, le mode de défaillance dominant n'est pas une prédiction exclusivement neutre, mais plutôt l'incapacité à apprendre la classe neutre (0) sur les fenêtres de validation et de test.

Split	Accuracy	Macro-F1	F1(-1)	F1(0)	F1(+1)
train	0.625273	0.458824	0.622106	0.027743	0.726623
val	0.693193	0.398764	0.369004	0.000000	0.827289
test	0.627273	0.424743	0.533700	0.000000	0.740528

Tableau 15 — Métriques L2 sous V1 (E5, régression logistique).

Split	Accuracy	Macro-F1	F1(-1)	F1(0)	F1(+1)
train	0.625273	0.455614	0.621762	0.023107	0.721975
val	0.703739	0.401000	0.370370	0.000000	0.832628
test	0.616883	0.408606	0.493976	0.000000	0.731844

Tableau 16 — Métriques L2 sous V1 (E6, LinearSVC).

9.6.2. Diagnostics par matrices de confusion (L2, test V1)

Les matrices de confusion sur le test V1 rendent explicite l'effondrement de la classe neutre : la colonne correspondant aux prédictions 0 est nulle.

	pred_−1	pred_0	pred_1
true_−1	194	0	263
true_0	33	0	235
true_1	43	0	772

Tableau 17 — Matrice de confusion L2 (E5, test V1 ; ordre des classes [−1, 0, +1]).

	pred_−1	pred_0	pred_1
true_−1	164	0	293
true_0	14	0	254
true_1	29	0	786

Tableau 18 — Matrice de confusion L2 (E6, test V1 ; ordre des classes [−1, 0, +1]).

Le même comportement est observable dans les diagnostics de fréquence des classes prédites.

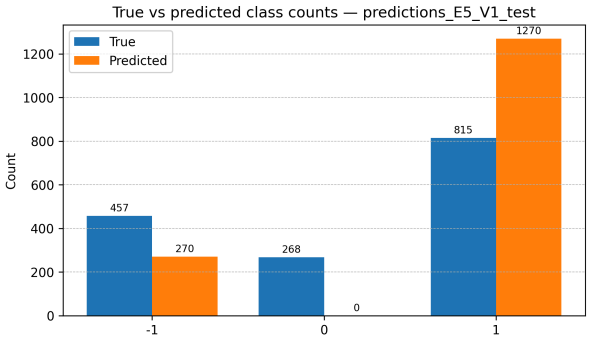

Fig. 11 — Fréquence des classes prédites L2 sur le test V1 (E5).

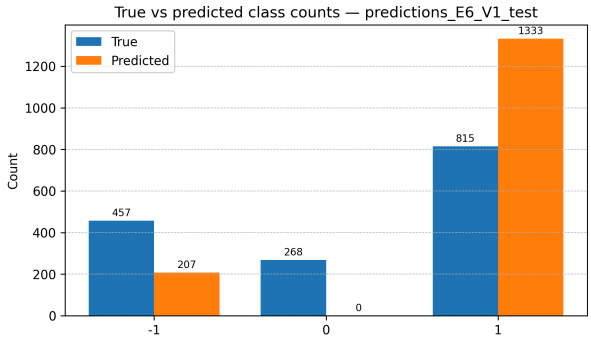

Fig. 12 — Fréquence des classes prédites L2 sur le test V1 (E6).

9.7. Résultats pli par pli sous V2 (E7 vs E8)

Les performances associées au label L2 sont évaluées sous V2 à partir de métriques calculées pli par pli. L'intérêt principal de ce schéma est de rendre visible l'hétérogénéité entre fenêtres de test : la performance peut varier sensiblement selon les blocs temporels, un effet qu'un **holdout** unique peut facilement masquer.

Pli	Accuracy	Macro-F1	F1 (-1)	F1 (0)	F1 (+1)
F1	0.687140	0.483264	0.652174	0.000000	0.797619
F2	0.685824	0.487119	0.676768	0.000000	0.784588
F3	0.511494	0.379064	0.498660	0.000000	0.638532
F4	0.693193	0.398764	0.369004	0.000000	0.827289

Tableau 19 — Métriques de test par pli sous V2 (E7, Régression logistique).

La moyenne non pondérée sur les plis de test V2 (telle que rapportée dans le Tableau 14) est :

- Accuracy : **0.644413**
- Macro-F1 : **0.437053**
- Moyenne de F1(0) : **0.000000**

Pli	Accuracy	Macro-F1	F1 (-1)	F1 (0)	F1 (+1)
F1	0.700576	0.493931	0.674157	0.000000	0.807636
F2	0.670498	0.473166	0.652055	0.000000	0.767442
F3	0.496169	0.358370	0.438746	0.000000	0.636364
F4	0.703739	0.401000	0.370370	0.000000	0.832628

Tableau 20 — Métriques de test par pli sous V2 (E8, LinearSVC).

Le résumé V2, calculé comme une moyenne non pondérée sur les plis de test (Tableau 14), est le suivant :

- Accuracy : **0.642745**
- Macro-F1 : **0.431617**
- Moyenne de F1(0) : **0.000000**

Les graphiques de fréquence des classes prédites, agrégés sur l'ensemble des plis de test, mettent en évidence le même comportement de collapse.

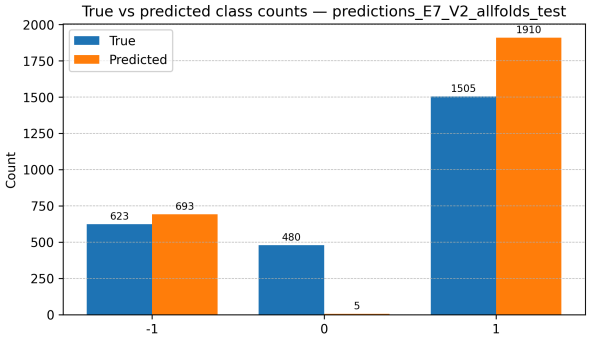

Fig. 13 — Fréquence des classes prédites pour L2, agrégée sur les plis de test V2 (E7).

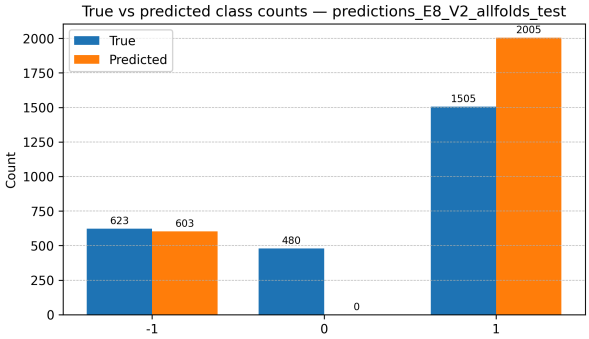

Fig. 14 — Fréquence des classes prédites pour L2, agrégée sur les plis de test V2 (E8).

Conclusion diagnostique (L2). Avec les baselines linéaires (F_CORE, sans pondération des classes), L2 atteint une Macro-F1 plus élevée que L1_Q. En revanche, la classe neutre (0) n'est pas correctement capturée sur les fenêtres de validation et de test. La performance provient surtout de la séparation des régimes directionnels (−1 vs +1), avec une variabilité sensible d'un pli à l'autre sous V2 — notamment un affaiblissement sur F3.

9.8. Diagnostic inter-familles : désaccord entre labels (L1_Q vs L2)

Étant donné que L1_Q et L2 encodent des concepts de régime différents (quantiles de rendements futurs versus heuristique de tendance), il est pertinent de mesurer directement leur degré d'accord. Une carte de chaleur comparant les labels y_L1_Q et y_L2.

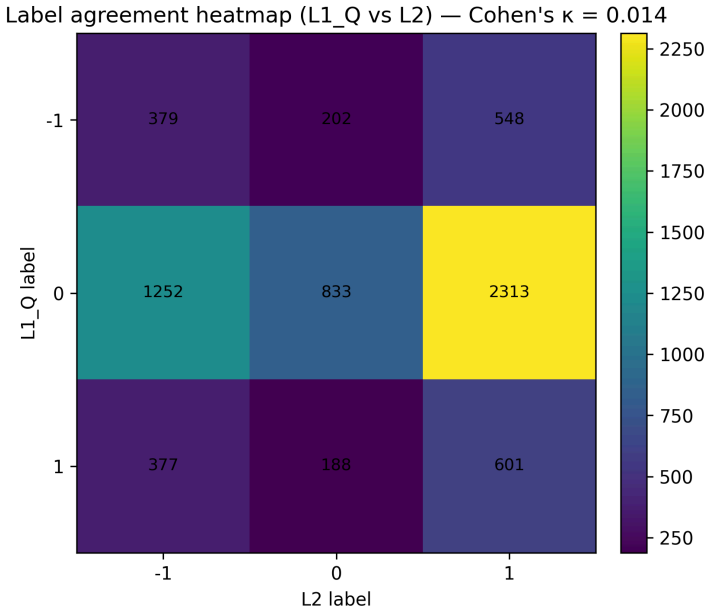

Fig. 15 — Carte de chaleur du désaccord entre labels (L1_Q vs L2).

Ce diagnostic rappelle une contrainte d'interprétation essentielle : comparer deux familles de labels revient à comparer la prédictibilité de deux cibles différentes. Les écarts de performance doivent donc être lus comme des différences de difficulté (et de signal exploitable) propres à chaque définition de régime, et non comme l'approximation d'une même vérité terrain.

9.9. Synthèse des modes de défaillance (résumé des baselines)

Deux modes de collapse qualitativement distincts apparaissent dans les expériences de base :

1. **Collapse de L1_Q vers la classe neutre (0)** sur certains blocs hors échantillon — Visible dans les diagnostics de fréquence des classes prédites sous V1 et V2.
2. **Évitement de la classe neutre (0) sous L2** (classe neutre jamais prédite) — Étayé par les scores par classe (F1(0) = 0.000) sur la validation/test V1 et sur l'ensemble des plis de test V2, et par les matrices de confusion où la colonne « prédit 0 » est nulle.

Ces constats suggèrent des pistes de robustesse (pondération des classes, variantes de features, modèles non linéaires). Elles ne sont toutefois pas intégrées aux résultats principaux : le mémoire se limite ici aux baselines contrôlées, et les extensions sont laissées à des travaux ultérieurs.

9.10. Conclusion du chapitre et transition vers le Chapitre 10

Sur l'ensemble des baselines linéaires utilisant F_CORE :

- **L1_Q** présente une performance équilibrée faible (Macro-F1 basse) et des diagnostics indiquant une séparation instable des régimes selon les blocs temporels.
- **L2** améliore la Macro-F1 et distingue plus clairement les régimes directionnels, mais échoue systématiquement à modéliser le régime **neutre** dans le cadre linéaire de base.

Le Chapitre 10 exploite les artefacts de prédiction sauvegardés lors de ces expériences afin d'évaluer le comportement des stratégies en aval. Le présent chapitre s'arrête volontairement à l'analyse des performances de classification et des diagnostics, sans formuler de revendications en termes de rentabilité ou de valeur économique.

10. Backtesting et analyse de stratégies

Ce chapitre évalue dans quelle mesure les prédictions de régimes produites par les expériences de classification se traduisent en comportements de trading significatifs. Les backtests sont utilisés à des fins diagnostiques : les régimes prédits sont mappés en positions de trading quotidiennes, des mesures de performance standard sont calculées, et les résultats sont comparés à des stratégies de référence simples. L'objectif n'est pas de revendiquer une stratégie de trading déployable, mais d'analyser l'utilité des signaux, leur robustesse sous une évaluation respectant le temps, ainsi que l'impact des modes d'échec de la classification sur les résultats de trading.

10.1. Spécification du backtest

10.1.1. Prix et définition des rendements

Soit close_t le prix de clôture quotidien au jour t. Le rendement logarithmique journalier est défini par :

$$r_t = \log\left(\frac{\text{close}_t}{\text{close}_{t-1}}\right).$$

Toutes les mesures de performance des stratégies sont calculées à partir des rendements logarithmiques journaliers. Lorsqu'une annualisation est requise (par exemple pour la volatilité), un facteur d'annualisation de 252 jours de bourse est utilisé.

10.1.2. Espace des signaux et timing d'exécution

Chaque stratégie produit un signal quotidien :

$$\text{signal}_t \in \{-1, 0, +1\},$$

qui est converti en position tradable à l'aide d'un décalage d'exécution d'un jour :

$$\text{position}_t = \text{signal}_{t-1}.$$

Le premier jour de chaque fenêtre de test est forcé à une position neutre :

$$\text{position}_0 = 0.$$

Si une prédiction est manquante après l'alignement avec la série de prix, elle est remplacée par la valeur neutre 0 avant l'application du décalage.

10.1.3. Rendement de la stratégie

Le rendement logarithmique quotidien de la stratégie est calculé comme suit :

$$r_t^{\text{strat}} = \text{position}_t * r_t$$

Les courbes d'équité sont obtenues en cumulant les rendements logarithmiques, puis en exponentiant la somme cumulée afin d'obtenir un indice d'équité simple destiné à la visualisation.

10.1.4. Coûts de transaction

Les coûts de transaction (frais, glissement, impact de marché) sont supposés nuls dans l'ensemble des backtests. Ce choix vise à simplifier l'interprétation et à isoler l'effet de la qualité des signaux ; il a toutefois pour effet de avantager mécaniquement les stratégies à forte rotation.

10.2. Stratégies et baselines

10.2.1. Stratégies issues de l'apprentissage automatique

Deux stratégies canoniques basées sur l'apprentissage automatique sont évaluées :

- **T1 (L1, régression logistique)** : le signal de trading correspond au régime prédit par le modèle dans $\{-1, 0, +1\}$.
- **T2 (L2, régression logistique)** : le signal de trading correspond au régime prédit par le modèle dans ($\{-1, 0, +1\}$).

Le passage du signal à la position est identique pour l'ensemble des stratégies :

- (+1) : position longue
- (0) : position neutre
- (−1) : position courte

10.2.2. Stratégies de référence

Deux stratégies de référence servent de points de comparaison :

- **B1 (détention USD)** : signal constant égal à (+1) (toujours long), exécuté avec le même décalage d'un jour et la même convention de position neutre au premier jour.
- **B2 (croisement de moyennes mobiles)** : signal généré par une règle de régime basée sur des moyennes mobiles (dans ($\{-1, 0, +1\}$)), puis exécuté avec le même décalage d'un jour.

10.3. Métriques rapportées

Les métriques principales rapportées dans ce chapitre sont les suivantes :

- Rendement logarithmique cumulé : $\sum_t r_t^{\text{strat}}$.
- Drawdown maximal : calculé à partir de la courbe d'équité comme le minimum de

$$\frac{\text{equity}}{\max(\text{equity})} - 1.$$

Des diagnostics complémentaires (par exemple volatilité, ratio de Sharpe de type simplifié, exposition et taux de rotation) sont utilisés lorsque nécessaire afin d'interpréter le comportement des stratégies.

10.4. Résultats sous V1 (fenêtre de test chronologique unique)

Sous le protocole d'évaluation V1, le comportement des deux stratégies issues de l'apprentissage automatique diffère nettement.

T1 (L1, régression logistique) aboutit à un comportement dégénéré : sur la fenêtre de test, le classifieur ne prédit que le régime neutre. Après application du décalage d'exécution, la stratégie reste donc strictement plate. L'exposition est quasi nulle et le rendement cumulé demeure négligeable.

T2 (L2, régression logistique) produit au contraire des positions longues et courtes non triviales. Sur la fenêtre de test V1, la performance cumulée est positive : elle dépasse la baseline toujours-longue et se situe légèrement au-dessus de la stratégie de croisement de moyennes mobiles.

10.4.1. Figure — Courbes d'équité sous V1

La **Figure** présente les courbes d'équité des stratégies T1, T2, B1 et B2 sur la période de test V1.

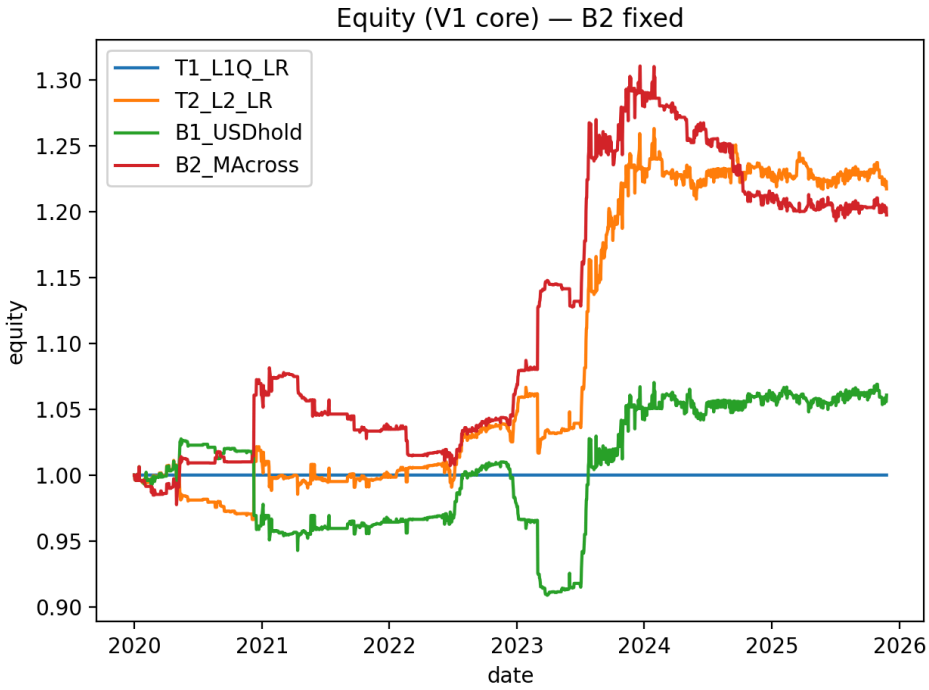

Fig. 16 — Courbes d'équité sous V1 (T1, T2, B1 et B2).

La figure confirme que T1 demeure plate sur l'ensemble de la fenêtre, tandis que T2 et B2 affichent une croissance modérée, et que B1 progresse plus lentement.

10.5. Résultats sous V2 (plis walk-forward)

Le protocole V2 évalue la robustesse à l'aide de quatre plis de test walk-forward (F1–F4). Les performances sont rapportées par pli, puis agrégées sous la forme d'une moyenne simple sur l'ensemble des plis.

10.5.1. Performance par pli

Stratégie	Pli	Rendement log cumulé	Drawdown max
B1 (USD hold)	F1	0.0943	−0.0573
	F2	0.0078	−0.1332
	F3	0.0680	−0.1394
	F4	0.1880	−0.0398
B2 (croisement MA)	F1	−0.0099	−0.1087
	F2	−0.1011	−0.2170
	F3	−0.4757	−0.3995
	F4	−0.1354	−0.1320
T2 (L2, logistique)	F1	0.1324	−0.0500
	F2	−0.1324	−0.2408
	F3	−0.2389	−0.2814
	F4	0.0937	−0.0563

Tableau 21 — Rendement logarithmique cumulé et drawdown maximal par pli sous V2.

Les performances varient fortement d'un pli à l'autre. T2 affiche de bons résultats sur F1 et F4, mais subit des pertes importantes sur F2 et F3. La stratégie B2 présente de mauvaises performances sur l'ensemble des plis, avec des pertes particulièrement sévères sur F3. La stratégie B1 reste positive sur tous les plis, bien que les drawdowns demeurent modérés.

10.5.2. Performance agrégée

Stratégie	Rendement log cumulé moyen	Drawdown max moyen
B1 (USD hold)	0.0895	−0.0924
B2 (croisement MA)	−0.1805	−0.2143
T1 (L1, logistique)	−0.0202	−0.0238
T2 (L2, logistique)	−0.0363	−0.1571

Tableau 22 — Performance moyenne sur les plis V2.

En moyenne, seule la stratégie B1 obtient un résultat systématiquement positif sur l'ensemble des plis. Les performances positives de T2 observées sur certains plis ne se généralisent pas, ce qui conduit à un rendement moyen négatif et à des drawdowns sensiblement plus élevés que ceux de B1.

10.5.3. Figures — Courbes d'équité V2 par pli

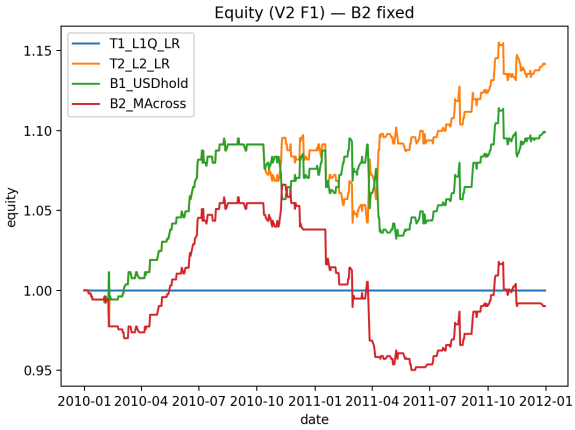

Fig. 17 — Courbe d'équité sous V2, pli F1.

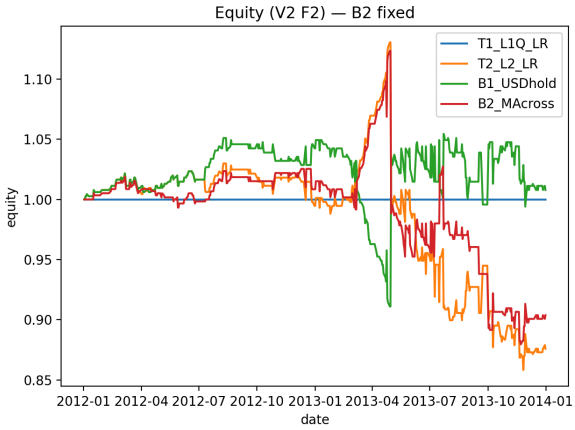

Fig. 18 — Courbe d'équité sous V2, pli F2.

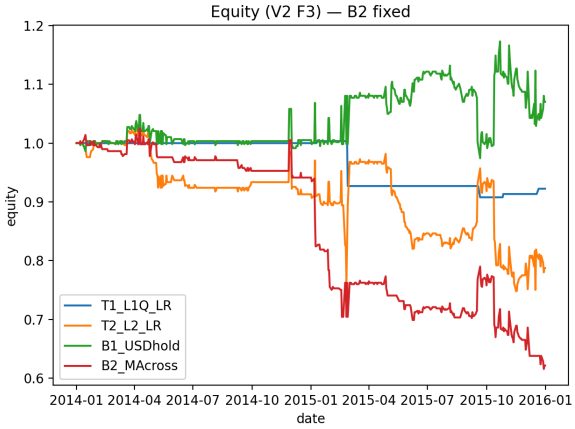

Fig. 19 — Courbe d'équité sous V2, pli F3.

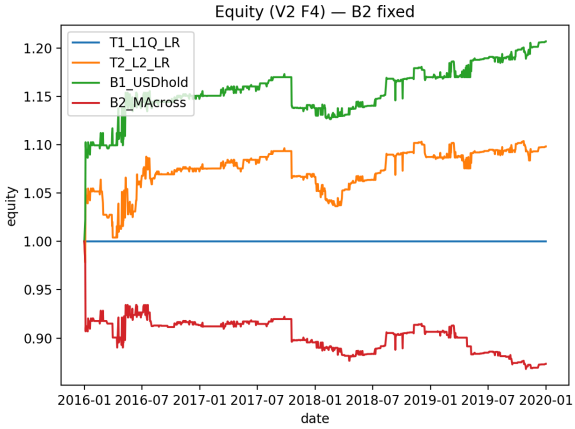

Fig. 20 — Courbe d'équité sous V2, pli F4.

Ces figures illustrent la forte non-stationnarité des performances des stratégies dans le temps, en particulier pour T2 et B2.

10.6. Comportement de classification et résultats de trading

Les résultats de trading reflètent directement les comportements de classification identifiés précédemment. Lorsqu'un classifieur s'effondre vers la prédiction exclusive de la classe neutre, la stratégie induite devient plate et non informative. À l'inverse, lorsque les prédictions neutres sont absentes, la stratégie reste presque continuellement investie, alternant entre positions longues et courtes. Un tel comportement accroît la sensibilité aux changements de régime et amplifie les drawdowns lorsque les erreurs de prédiction se concentrent dans le temps.

Ces mécanismes expliquent pourquoi T1 délivre une performance triviale et pourquoi T2 présente une forte variabilité d'un pli à l'autre.

10.7. Conclusion du chapitre

Les backtests montrent qu'une performance favorable obtenue sur une unique partition chronologique peut être trompeuse. Sous une évaluation walk-forward, la stratégie toujours-longue constitue l'approche la plus stable, tandis que les stratégies pilotées par apprentissage automatique présentent une forte dépendance aux périodes et une performance moyenne négative. Globalement, ces résultats renforcent l'importance d'une validation respectant strictement le temps et mettent en évidence la manière dont les modes d'échec de la classification se traduisent directement en comportements de trading.

11. Discussion et menaces à la validité

11.1. Interprétation des résultats

Les expériences E1–E8 conduisent à trois constats, qui s'expliquent principalement par (i) la définition des labels, (ii) le protocole de validation temporelle, et (iii) la manière dont ces sorties se traduisent en backtest.

Les labels conditionnent la performance équilibrée. À features identiques et avec les mêmes baselines linéaires, L2 (régimes fondés sur indicateurs) obtient une Macro-F1 hors échantillon sensiblement plus élevée que L1 (quantiles de rendements). Sur MRU/USD et avec F_CORE, cela suggère que les régimes L2 sont davantage séparables par des frontières linéaires, tandis que L1 correspond à une cible de court horizon plus bruitée.

La classe neutre est le point de rupture. Dans les deux familles de labels, la classe 0 n'est pas capturée de manière fiable par les modèles linéaires. Sous L2 (E5–E8), elle est très rarement prédite en validation et en test, ce qui se reflète par un F1 nul pour cette classe. Sous L1, l'échec apparaît souvent sous la forme inverse : le modèle se replie sur la prédiction "neutre" pour une grande partie des observations, ce qui peut maintenir une accuracy correcte tout en tirant la Macro-F1 vers le bas. Les matrices de confusion indiquent ainsi que, dans ces conditions, la classification à trois classes se dégrade en pratique vers un comportement à une ou deux classes.

Le walk-forward durcit l'évaluation et met en évidence l'instabilité temporelle. Les performances sous V1 sont en général plus élevées que sous V2, et V2 rend visible l'hétérogénéité entre fenêtres de test : les résultats varient selon les périodes, ce qui limite les conclusions tirées d'un unique **holdout**.

11.2. Comment la classification se traduit en backtest

Les résultats de backtesting (Chapitre 9) découlent directement des séquences de prédictions (Chapitre 8) et de la règle d'exécution (décalage d'un jour). Deux profils d'exposition en découlent.

- Si le classifieur prédit majoritairement 0, la stratégie reste à plat : l'exposition est quasi nulle et la performance demeure mécaniquement proche de zéro (hors hypothèses spécifiques).
- Si le classifieur prédit surtout ±1 et très rarement 0, la stratégie est presque toujours investie ; la performance dépend alors du biais directionnel et de la fréquence des changements de position.

Ces mécanismes permettent de lire les résultats : en V1, L1/T1 est essentiellement à plat lorsque le modèle prédit quasi exclusivement la classe neutre ; à l'inverse, en V1, L2/T2 prend des positions longues et courtes et surperforme la baseline toujours-long sur cette période. En V2, cet avantage ne se maintient pas : la performance moyenne de L2 devient négative et les drawdowns dépassent ceux de la baseline, malgré une baseline toujours-long positive sur chaque pli. Autrement dit, le backtest prolonge les diagnostics de classification : un signal dégénéré conduit à une règle de trading dégénérée, et ne soutient pas une surperformance stable sous un protocole temporel strict.

11.3. Comparaison aux attentes

Ces constats sont cohérents avec l'intuition classique du ML sur séries financières. Un schéma **walk-forward** fournit des estimations plus conservatrices et rend explicite la dépendance aux périodes, ce qui éclaire la dégradation de V1 vers V2 et la variabilité inter-plis. La difficulté à apprendre un régime neutre peut également être reliée au déséquilibre de classes et aux limites d'un modèle linéaire optimisé avec un objectif standard, qui tend à simplifier la tâche vers un comportement quasi binaire. Enfin, le fait qu'une baseline naïve (toujours-long) égale ou dépasse des stratégies pilotées par ML sous V2 s'inscrit dans la prudence empirique du **financial ML** : des signaux instables résistent rarement à une évaluation strictement respectueuse du temps.

11.4. Menaces à la validité

11.4.1. Validité de construit (définitions des labels)

Les deux familles de labels restent des constructions opérationnelles : elles ne correspondent pas à des régimes latents observés directement. L1 dépend de choix de conception (horizon, seuils de quantiles, conventions d'échelle), tandis que L2 dépend des fenêtres de moyennes mobiles et de la définition retenue pour la pente (ou d'éventuels seuils). Ces paramètres déterminent la persistance des régimes, l'équilibre des classes et la fréquence des transitions. Les conclusions sur la « prédictibilité » doivent donc être comprises comme valables au regard de ces définitions de travail, et non comme un énoncé général sur un régime de marché universel.

11.4.2. Validité interne (fuite d'information et risques d'alignement)

Les découpages temporels et la standardisation **train-only** réduisent les risques de fuite d'information, mais un pipeline de séries temporelles reste vulnérable à des erreurs d'alignement. Une jointure de dates incorrecte, une politique de NaN mal appliquée, ou un décalage cible–features peut biaiser les métriques de classification et, en aval, les backtests. Comme le backtest consomme des prédictions persistées, la validité dépend en particulier d'un indexage strictement cohérent et d'une convention d'exécution respectueuse du temps (gestion du premier pas, décalage d'un jour).

11.4.3. Validité des conclusions statistiques (variance et support de test limité)

Même sous V2, les résultats reposent sur une seule série d'actif et un nombre fini de plis. La variabilité inter-plis indique une variance élevée, ce qui affaiblit les revendications de supériorité d'une configuration sur une autre. Les conclusions les plus défendables sont donc qualitatives et centrées sur les modes d'échec (effondrement de classes, écart de robustesse entre V1 et V2) plutôt que sur des écarts numériques marginaux.

11.4.4. Validité externe (généralisation)

L'étude se limite à MRU/USD ; les résultats peuvent ne pas se transférer à d'autres devises, en particulier à des marchés plus liquides présentant une dynamique et une microstructure différentes. De plus, le jeu de features est volontairement compact et purement technique ; si des facteurs exogènes dominent les transitions de régimes, des variables plus riches (macroéconomiques, événements) pourraient être nécessaires pour apprendre des régimes de manière robuste.

11.4.5. Validité du backtest (hypothèses simplificatrices)

Les backtests sont mobilisés ici avant tout comme outils de diagnostic, et non comme preuves de stratégies directement déployables. Certaines hypothèses simplificatrices — par exemple des coûts de transaction nuls et une exécution avec un décalage fixe d'un jour — peuvent modifier sensiblement la performance nette, en particulier lorsque la stratégie tourne fréquemment. Les résultats de trading doivent donc être lus comme une traduction contrôlée des prédictions en profils d'exposition et de drawdown, plutôt que comme une démonstration de profitabilité opérationnelle.

11.5. Limites pratiques et synthèse

Le mémoire adopte volontairement un cadre sobre : modèles linéaires, jeu de features restreint et absence de tuning extensif. Ce cadrage améliore l'interprétabilité et réduit les degrés de liberté, mais il limite aussi la capacité à capturer des frontières de régime non linéaires. Dans ces contraintes, les résultats pointent vers une conclusion cohérente : la définition des labels et le protocole d'évaluation temporelle expliquent une large part des performances observées ; la classe neutre n'est pas apprise de manière fiable par les classifieurs linéaires retenus ; et un gain mesuré sur un seul **holdout** ne se retrouve pas nécessairement comme effet robuste sous validation **walk-forward**.

12. Conclusions et perspectives

Ce mémoire présente une étude expérimentale, contrôlée et reproductible de la classification supervisée de régimes de marché appliquée au taux de change quotidien MRU/USD. L'ambition n'était pas de produire une stratégie de trading optimisée, mais d'évaluer — dans un cadre méthodologique strict — l'influence de deux choix qui structurent les conclusions : (i) la définition des labels et (ii) le protocole de validation temporelle.

Deux définitions opérationnelles de régimes ont été comparées : (L1), fondée sur des quantiles de rendements futurs, et (L2), fondée sur une logique de tendance via moyennes mobiles. Elles ont été évaluées avec deux baselines linéaires (régression logistique et SVM linéaire) entraînées sur un jeu de features volontairement compact. L'évaluation respecte strictement la chronologie, à la fois via un découpage chronologique unique (V1) et via une validation walk-forward multi-plis (V2).

Dans ce cadre, un résultat transversal se dégage : les choix méthodologiques (labels, validation) expliquent une part majeure des performances observées, davantage que le choix du classifieur au sein de la famille linéaire considérée.

12.1. Réponses aux questions de recherche

RQ1 — Conception des labels (L1 vs L2). La définition du régime conditionne directement la difficulté du problème. Dans cette étude, L2 conduit à des performances équilibrées plus élevées que L1. Sous L1, les modèles se replient fréquemment vers des prédictions dominées par la classe neutre ; sous L2, la discrimination directionnelle (−1 vs +1) apparaît plus régulièrement.

Un point critique reste cependant partagé : la classe neutre (0) n'est pas apprise de manière fiable par les modèles linéaires retenus. Cette difficulté se traduit par des comportements dégénérés (sur-prédiction de 0, ou au contraire disparition effective de 0), visibles dans les diagnostics par classe. C'est l'un des enseignements centraux du mémoire.

RQ2 — Protocole de validation (V1 vs V2). Le protocole d'évaluation influence substantiellement la lecture des performances. Un **holdout** unique (V1) peut refléter une période spécifique et conduire à des conclusions trop favorables. À l'inverse, V2 sert de test de robustesse plus exigeant : il fournit des estimations plus conservatrices et met en évidence une variabilité marquée selon les périodes. Cette hétérogénéité limite la portée de conclusions fondées sur une seule fenêtre de test et justifie une évaluation multi-périodes.

RQ3 — Traduction des régimes prédits en performance de trading. Sous une validation walk-forward stricte, les signaux issus des modèles de classification n'aboutissent pas à une surperformance stable par rapport à des baselines simples. La stratégie toujours-long reste positive sur l'ensemble des plis V2, tandis que les stratégies pilotées par les prédictions de régimes sont négatives en moyenne.

Ce constat prolonge les diagnostics de classification. Lorsque le modèle prédit majoritairement 0, la stratégie reste quasi à plat ; lorsque la classe 0 est évitée, l'exposition devient quasi permanente, avec davantage de rotations et des drawdowns plus prononcés. Dans ce cadre, le backtest agit comme une traduction contrôlée du comportement de prédiction, plus que comme une validation économique indépendante.

12.2. Contributions

Les contributions de ce mémoire sont principalement méthodologiques et sont volontairement délimitées par un périmètre strict.

- Comparaison contrôlée de définitions de régimes. Deux schémas de labels explicites sont comparés dans un cadre reproductible, à features et modèles constants, ce qui met en évidence l'effet structurant de la définition des cibles sur l'équilibre des classes, la séparabilité et les modes d'échec.
- Mise en œuvre explicite de protocoles de validation temporelle. La comparaison entre un **holdout** chronologique et une validation walk-forward multi-plis montre que le protocole de validation modifie directement les conclusions, en classification comme en backtest.
- Analyse diagnostique centrée sur les classes. Le recours systématique aux métriques par classe et aux matrices de confusion permet d'identifier des pathologies structurelles — notamment la fragilité de la classe neutre — qui seraient largement masquées par des métriques agrégées.
- Chaîne transparente signal → position → performance. Un backtest minimaliste relie les prédictions à des règles d'exposition simples (long / short / flat) et explicite comment des erreurs de classification se traduisent en exposition, drawdowns et trajectoires de performance.

Ces contributions sont assumées comme méthodologiques : le mémoire ne revendique pas une profitabilité déployable et traite le backtest comme un outil d'analyse.

12.3. Limites

Les résultats doivent être interprétés au regard de limites assumées : un seul actif (MRU/USD), deux définitions heuristiques de labels, un jeu de features techniques restreint et des modèles linéaires. Le fait que la classe neutre ne soit pas apprise de manière robuste suggère soit une inadéquation entre la définition des labels et l'information contenue dans les features, soit une limite des frontières de décision linéaires dans ce contexte.

La validation walk-forward met aussi en évidence une dépendance aux périodes, compatible avec un environnement non stationnaire. Enfin, les backtests reposent sur des hypothèses simplificatrices (coûts idéalisés, exécution à décalage fixe) et ne doivent pas être interprétés comme des stratégies directement implémentables.

12.4. Perspectives

Les résultats suggèrent plusieurs prolongements naturels :

1. Traiter explicitement la fragilité de la classe neutre, via des objectifs pondérés, du rééchantillonnage ou des formulations alternatives, en documentant le compromis entre récupération de 0 et performance globale.
2. Augmenter la capacité de représentation de manière contrôlée, en évaluant des modèles non linéaires sous la même discipline de validation temporelle.
3. Enrichir et auditer le jeu de features, notamment via des analyses d'ablation, afin d'identifier les apports réels et de limiter les gains artificiels.
4. Revisiter la définition des régimes, avec des labels adaptatifs, multi-horizons ou probabilistes, puis réévaluer leur apprenabilité sous les mêmes protocoles.
5. Renforcer le réalisme des backtests, en étudiant la sensibilité aux coûts, à l'exécution et aux conventions de position.
6. Étendre la validation externe, en appliquant le même cadre à d'autres actifs afin d'évaluer la généralité des constats.

12.5. Conclusion générale

La conclusion principale est méthodologique : en classification de régimes sur séries financières, la définition des labels et le protocole de validation déterminent en grande partie ce que mesure la "performance". Une évaluation strictement temporelle, complétée par des diagnostics par classe, est indispensable pour éviter des lectures trop optimistes fondées sur des métriques agrégées.

Les résultats instables sous walk-forward jouent ici un rôle informatif : ils localisent les points de fragilité du pipeline (classe neutre, dépendance aux périodes, passage signal $\longrightarrow$ exposition) et fournissent une base claire pour des améliorations futures, dans un cadre reproductible et auditable.

Références

[1] O. Academic, « Predictive Modelling Overview (quote attribution: “In God We Trust, all others bring data.”) ». Consulté le: 16 décembre 2025. [En ligne]. Disponible sur: https://academic.oup.com/book/38955/chapter/338166767

[2] J. D. Hamilton, « A new approach to the economic analysis of nonstationary time series and the business cycle », *Econometrica*, vol. 57, nº 2, p. 357-384, 1989, doi: 10.2307/1912559.

[3] K.-j. Kim, « Financial time series forecasting using support vector machines », *Neurocomputing*, vol. 55, nº 1–2, p. 307-319, 2003, doi: 10.1016/S0925-2312(03)00372-2.

[4] W. Huang, Y. Nakamori, et S.-Y. Wang, « Forecasting stock market movement direction with support vector machine », *Computers & Operations Research*, vol. 32, nº 10, p. 2513-2522, 2005, doi: 10.1016/j.cor.2004.03.016.

[5] W. J. Hsu, « Predicting and Capitalizing on Two Types of Stock Bear Markets in the U.S. ». 2016.

[6] C. Bergmeir et J. M. Ben\itez, « On the use of cross-validation for time series predictor evaluation », *Information Sciences*, vol. 191, p. 192-213, 2012, doi: 10.1016/j.ins.2011.12.028.

[7] R. J. Hyndman et G. Athanasopoulos, « Forecasting: Principles and Practice ». [En ligne]. Disponible sur: https://otexts.com/fpp3/

[8] scikit-learn developers, « TimeSeriesSplit — scikit-learn documentation ». [En ligne]. Disponible sur: https://scikit-learn.org/stable/modules/generated/sklearn.model_selection.TimeSeriesSplit.html

[9] M. López de Prado, *Advances in Financial Machine Learning*. Wiley, 2018.

[10] M. López de Prado, *Machine Learning for Asset Managers*. Cambridge University Press, 2020.

[11] D. H. Bailey, J. Borwein, M. López de Prado, et Q. J. Zhu, « The Probability of Backtest Overfitting ». [En ligne]. Disponible sur: https://ssrn.com/abstract=2326253

[12] H. R. Arian et others, « Backtest overfitting in the machine learning era ». 2024.

[13] Q. Wu et others, « A Labeling Method for Financial Time Series Prediction Based on Trends », *Entropy*, vol. 22, nº 10, p. 1162, 2020, doi: 10.3390/e22101162.

[14] M. Naeem, H. S. Jassim, et D. Korsah, « The Application of Machine Learning Techniques to Predict Stock Market Crises in Africa », *Journal of Risk and Financial Management*, vol. 17, nº 12, p. 554, 2024, doi: 10.3390/jrfm17120554.

[15] H. Alghamdi et S. Alqithami, « A robust machine learning framework for stock market classification », *Expert Systems with Applications*, vol. 294, p. 128573, 2025, doi: 10.1016/j.eswa.2025.128573.